基于多源数据融合与残差图卷积网络的成都市地铁短时客流预测调查报告



摘 要

在《交通强国建设纲要》与“双碳”目标驱动下，城市轨道交通正从规模扩张转向精细化运营，短时客流预测是衔接数据感知与智能调度的关键技术。成都作为西部轨道交通规模最大的城市，运营里程超 600 公里、日均客流超 600 万人次，其环线放射拓扑与盆地气候为检验预测方法提供了理想场景。

本研究使用成都地铁 2023 年 4 月 26 日至 5 月 26 日连续 31 天的 AFC 刷卡数据，收集了融合气温、降水和 AQI 指标等在内的 18 项影响因素，首先完成上述多源数据的合并与时间网格规整，将累计客流差分转换为 5 分钟区间增量，并对异常值与缺失值进行处理。其次，构建包含拓扑特征、时间特征与外部特征的多维度特征体系：筛选 37 个站点构建拓扑邻接矩阵，引入 7 维时间特征，并对风向等周期性外部变量实施正余弦循环编码。经长表转宽、EMA 基线计算与 24 步滑动窗口切分后，构建季节基线编码器：该编码器接收 EMA 滑动均值、昨日及上周同期地铁客流三类统计特征，通过三层全连接网络输出可学习的周期基线预测，使后续分支仅需学习偏离基线的非线性残差，显著降低深度网络的拟合难度。

本文将季节基线与残差学习相结合，构建了 SeSTAR-Net 模型。（1）空间编码器采用两个参数独立的 ResGCN 分支分别处理进出站客流，通过残差连接缓解过平滑，分离设计适配不同空间动力学模式。（2）时间编码器采用 Temporal Transformer 多头注意力机制，解决 LSTM 路径衰减问题。（3）外部编码器通过 MLP 将环境因子压缩至 8 维，融合层将四分支输出拼接为 168 维向量，最终预测值为基线与残差之和。本研究将 SeSTAR-Net 与 3 种基线模型在 3 种时间粒度、有无外部特征共 6 种配置下开展全矩阵对比实验，其在 15 分钟粒度含外部特征时性能最优，决定系数 R^2为 0.9481。消融实验表明空间编码器贡献最大，各模块均显著有效。外部特征效用呈 U 型，其价值由与预测粒度的匹配度决定。

本研究从统计稳定性、预测不确定性和抗干扰鲁棒性三方面对 SeSTAR-Net 模型进行检验。Bootstrap 重采样决定系数 R^2的置信区间为[0.940, 0.949]，证明该模型具有统计可靠性；蒙特卡洛 Dropout 法显示进出站预测不确定性低且符合真实客流规律；高斯噪声注入实验表明随噪声标准差增至 0.20 时 RMSE 上升至 235，性能退化幅度为 173.7%，说明模型性能退化平滑可控。综上，SeSTAR-Net 模型兼具高精度与强可靠性，为实际运营迁移提供了验证依据。

关键词：短时客流预测；图卷积网络；残差学习；多源数据融合

目 录

第一章 引言 1
1.1 研究背景与问题 1
1.2 研究目的与意义 2
1.3 国内外研究现状 2
1.4 论文结构与安排 4
第二章 数据与实验设计 5
2.1 数据范围与来源 5
2.2 数据预处理 6
2.3 特征工程与序列构建 8
2.4 数据划分与实验设计 11
第三章 基于 SESTAR-NET 的地铁数据分析 12
3.1 设计理念与总体架构 12
3.1.1 残差学习：季节基线编码器 12
3.1.2 时空特征编码：ResGCN 与 TemporalTransformer 13
3.1.3 外部编码器与对比模型 ResLSTM 14
第四章 客流时空特征与预测性能 16
4.1 客流空间特征 16
4.2 预测性能与基准对比 19
4.3 粒度效应与外部特征贡献 20
4.4 RESLSTM 对比与多模型验证 24
第五章 消融实验与深度分析 31
5.1 训练过程与季节基线验证 31
5.2 空间编码器的作用 32
5.3 进出站分离与误差诊断 34
5.4 模型鲁棒性与稳定性分析 37
第六章 结论与建议 42
6.1 主要结论 42
6.2 对策建议 43
6.3 研究局限与未来展望 44
参考文献 46

图表目录

图 1.1 论文框架流程图 4
图 2.1 成都市地铁运营线路图 5
表 2.1 特征说明 8
表 2.2 输入张量说明 10
表 2.3 输出张量说明 10
图 3.1 SeSTAR-Net 模型框架图 12
图 4.1 2023 年 4 月 26 日至 5 月 26 日每日全网总客流量时序图 16
图 4.2 左：5 分钟全网总客流的频率分布直方图右：5 分钟站点级客流分布 17
图 4.3 左：按星期划分日均客流量柱状图右：按小时划分平均客流柱状图或折线图 18
图 4.4 15 分钟粒度下 SeSTAR-Net 的综合评估指标仪表盘 19
图 4.5 测试集期间全站点聚合的预测值与实际值时序对比 20
图 4.6 5 分钟粒度下 SeSTAR-Net 的综合评估仪表盘 21
图 4.7 10 分钟粒度下 SeSTAR-Net 的综合评估仪表盘 21
图 4.8 15 分钟粒度下移除外部特征后的综合评估仪表盘 22
图 4.9 15 分钟粒度下无外部特征的时序对比 23
表 4.1 六组配置的完整对比数据 23
图 4.10 ResLSTM 在 15 分钟粒度含外部特征下的预测效果对比 24
图 4.11 ResLSTM 在 15 分钟粒度无外部特征下的预测效果对比 25
图 4.12 ResLSTM 在 5 分钟粒度含外部特征下的预测效果对比 26
图 4.13 ResLSTM 在 5 分钟粒度无外部特征下的预测效果对比 27
图 4.14 ResLSTM 在 10 分钟粒度含外部特征下的预测效果对比 27
图 4.15 ResLSTM 在 10 分钟粒度无外部特征下的预测效果对比 28
表 4.2 对比实验 29
图 5.1 SeSTAR-Net 在 15 分钟粒度下的训练曲线 31
图 5.2 季节基线预测（绿色虚线）与完整 SeSTAR-Net 预测（橙色实线）的对比 31
图 5.3 各站点的 R^2分布与 WMAPE 分布 32
图 5.4 一天内不同时段的预测误差分布 33
图 5.5 进站客流（上）与出站客流（下）的预测效果对比 34
图 5.6 预测误差（预测值−实际值）随时间的变化曲线 35

图 5. 7 测试集 7 天中每天的 R^2和 WMAPE 36
图 5. 8 预测残差的直方分布与拟合的正态曲线 36
图 5. 9 四个关键评价指标的 Bootstrap 经验分布直方图 38
图 5. 10 进站与出站流量预测任务中的不确定性特征 39
图 5. 11 不同强度高斯噪声扰动下的 RMSE 变化曲线 40
图 5. 12 各站点的性能分布特征 41

第一章 引言

本章从国家战略与城市发展、政府治理、民生体验三个维度铺陈研究背景，进而明确研究目的与理论/实践双重意义，系统梳理国内外短时客流预测方法的演进脉络与现存不足，最后给出全文的章节结构安排。

1.1 研究背景与问题

过去二十年，中国经历了人类历史上规模最大的城市化进程。截至 2025 年底，全国常住人口城镇化率已突破 68%，超过 9.5 亿人居住在城市。轨道交通以其大容量、高效率、低排放的突出优势，被明确置于国家综合交通体系的核心位置。《交通强国建设纲要》提出“构建便捷顺畅的城市（群）交通网”，《“十四五”现代综合交通运输体系发展规划》将城市轨道交通运营里程目标锚定在 10000 公里以上。截至 2025 年，全国已有 58 个城市开通轨道交通，运营里程突破 12000 公里，日均客运量超 9000 万人次。在“双碳”目标硬约束下，轨道交通作为单位客运量碳排放最低的机动化出行方式，其建设力度还将持续加大。2024 年国务院印发的《关于推进城市公共交通高质量发展的若干意见》明确提出“推动大数据、人工智能等新技术在城市公共交通领域的深度应用，提升运营调度智能化水平”——短时客流预测正是这一政策导向下最具直接应用价值的技术突破点。

然而，线网规模的扩张并不自动等同运营效率的提升。当城市地铁从“十字骨架”发展为“放射+环网”结构时，客流时空分布的非均衡性急剧加剧——早晚高峰的潮汐式冲击、换乘站的持续高负荷、节假日与大型活动的突发客流，使得仅凭人工经验已难以做出最优调度决策。从政府治理视角看，早晚高峰大客流冲击（单小时进出站量可达平峰时段的 3 至 5 倍）若缺乏提前预判，极易引发站台拥挤、列车超员等安全风险——2023 年北京地铁昌平线追尾事故的调查报告明确指出“极端天气条件下的大客流积压是事故的重要诱因”。从事后应急成本看，启动大客流限流、地面公交接驳等事后措施的成本可达事前预防性调度的 3 倍以上。因此，能够在 15 至 30 分钟前准确预判站点级客流变化的预测系统，本质上是将运营管理从“被动响应”切换为“主动预判”。

从民生维度看，基于国内 12 个城市地铁刷卡数据的研究表明，同一通勤者早高峰出行时间波动可达±15 分钟以上，其中约 40%直接归因于列车拥挤和站台限流。每人每年为此付出的隐性时间缓冲成本高达 125 小时。当短时预测系统能以 15 分钟粒度提前预知客流变化时，运营方不仅可动态加密班次，还可通过 App 推送替代线路建议，将“事后排队”转化为“事前分流”，并间接推动绿色出行——地铁可预期性提高促使部分私家车出行者回归公共交通。

将视角聚焦于成都——西部地区人口规模最大、经济首位度最高的中心城市。截至 2023 年底，成都地铁开通 14 条线路、运营里程超 600 公里、日均客流超 600 万人次，稳居全国第四。其环线加放射线的拓扑形态导致换乘站压力高度集中其中天府广场、火车南站等核心换乘站日均客流可达普通站点的 4 倍，盆地地形导致的静风与逆温天气使空气质量波动成为不可忽视的出行因素。这些特征使成都成为检验“多源融合+周期先验+残差学习”预测框架的理想试验场。

1.2 研究目的与意义

本研究的目的由三条核心线索牵引。第一，在模型输入层面，探索将空气质量指数（AQI）等细粒度环境因素纳入地铁短时客流预测特征体系的可行性与有效性，拓展多源数据融合的维度。第二，在模型架构层面，构建一种融合 EMA 季节基线先验、独立进出站图卷积空间编码、Transformer 自注意力时序编码与 MLP 外部特征编码的多分支残差预测模型，以同时回应现有研究在进出站分离建模、周期先验显式利用和时序依赖高效捕捉三个方向上的不足。第三，在工程验证层面，设计并实施一套从原始 AFC 数据到模型可消费张量的完整数据处理流水线，并通过全矩阵多模型对比、逐模块消融实验和多维度鲁棒性检验，为模型的实际部署提供系统性的实验证据。

研究意义可从理论与应用两个层面阐述。在理论层面，本研究首次将空气质量指标纳入地铁短时客流预测框架，并通过全矩阵对比实验量化了外部特征在不同预测粒度下的差异化贡献（U 型曲线），为多源外部因素融合的粒度匹配理论提供了实证基础。在模型方法论层面，SeSTAR-Net 将 ES-RNN/N-BEATS 风格的残差学习范式引入图卷积混合预测架构——模型仅学习偏离 EMA 基线的残差而非从零预测绝对值——这一策略在理论上的优势在于降低了深度网络的拟合难度并提升了泛化稳定性，其实验验证为后续研究提供了可参考的架构范式。

在应用层面，精准的短时客流预测可为成都地铁的运营管理提供直接支撑：依据预测结果实施动态运力调配以缓解高峰拥挤，针对工作日/周末/节假日制定差异化运行图，利用拓扑空间特征优化线网规划与换乘接驳设计，以及推动数据开放与模型工程化落地以支撑智慧交通决策。成都 2023 年大运会期间地铁瞬时客流峰值较平日高出 40%以上的事实，为预测模型在重大活动交通保障中的应用价值提供了直接注脚。

1.3 国内外研究现状

围绕短时客流预测这一命题，学术界已经历了从传统统计方法到机器学习，再到深度学习方法与混合模型的完整技术演进路线。在早期阶段，传统统计模型占据主导。Zhu 等人（2019）指出传统统计模型在复杂路网场景下亟需结合空间

信息进行完善。强添纲等人（2021）利用 SARIMA 与 GA-BP 神经网络构建组合模型，有效提升了周期性客流的预测精度。Liu 等人（2022）利用 PSO-LSTM 对 AFC 数据进行短时客流预测，证明了智能优化算法在适应客流非线性变化方面的有效性。Wu 等人（2023）通过时间序列分解与强化学习集成，发现传统模型更适用于刻画平稳序列的线性趋势。Katambire 等人（2023）的对比研究进一步证实，ARIMA 在线性平稳序列上表现良好，而 LSTM 在非线性波动场景下优势更为突出。总体而言，传统统计方法结构简单、可解释性强，但在处理复杂非线性与空间关联关系方面存在先天不足。

随着数据规模扩大与算力提升，深度学习方法逐渐成为主流。Luo 等人（2019）利用 KNN-LSTM 组合模型提升了局部区域的预测精度。Park 等人（2022）利用随机森林、SVM 等机器学习框架融合多源外部特征，验证了非线性模型的显著优势。在图卷积网络方面，Han 等人（2019）首次利用时空图卷积神经网络（STGCN）将地铁真实路网拓扑纳入预测框架，奠定了空间拓扑建模的基础。Zheng 等人（2020）将注意力机制与 Conv-LSTM 结合，为关键时序与空间节点自动分配更高权重。Zhao 等人（2022）构建了动态多图卷积网络，通过自适应图结构刻画站点间动态变化的客流空间关联。Hou 等人（2022）的研究表明，组合式深度学习模型通过融合各子网络优势显著提升了客流拟合精度。

为进一步整合不同网络结构的优势，融合残差、图卷积、时序网络与注意力机制的混合模型不断涌现。Zhang 等人（2020）提出的 ResLSTM 架构创新性地融合了 ResNet、GCN 与 Attention LSTM，构建了四分支并行结构，为后续研究提供了重要的参考框架。Zeng 等人（2023）将知识图谱与分离注意力关系图卷积结合，提升了模型对站点、线路与客流之间复杂异构关联的推理能力。张阳等人（2024）引入多头图注意力机制，从多子空间视角增强了对复杂路网拓扑的深层次刻画。Tang 等人（2025）构建了深度时空依赖的 ConvLSTM 网络，强化了高度动态场景下的预测鲁棒性。

综合梳理现有研究，可识别出三条尚未被充分解决的线索。其一，多数模型将进出站客流混合编码，但现实中的空间依赖关系具有非对称性——早高峰居住型站点出站量远高于进站量，办公区则相反，混合编码导致两种空间动力学信号相互干扰。其二，研究者为追求单项指标提升而堆叠模块，却忽视了地铁客流极强的日周期与周周期规律——充分利用这一强先验，让模型仅学习偏离基线的残差，可同时降低学习难度和提高泛化稳定性，但这一思路尚未得到充分贯彻。其三，空气质量等细粒度环境因素对居民出行行为的影响已被公共卫生与环境经济学领域广泛证实，但在轨道交通客流预测领域几乎被忽略。上述三条线索共同构成了本研究的出发点。

1.4 论文结构与安排

本文共分六章，各章内容安排如图 1.1 所示。

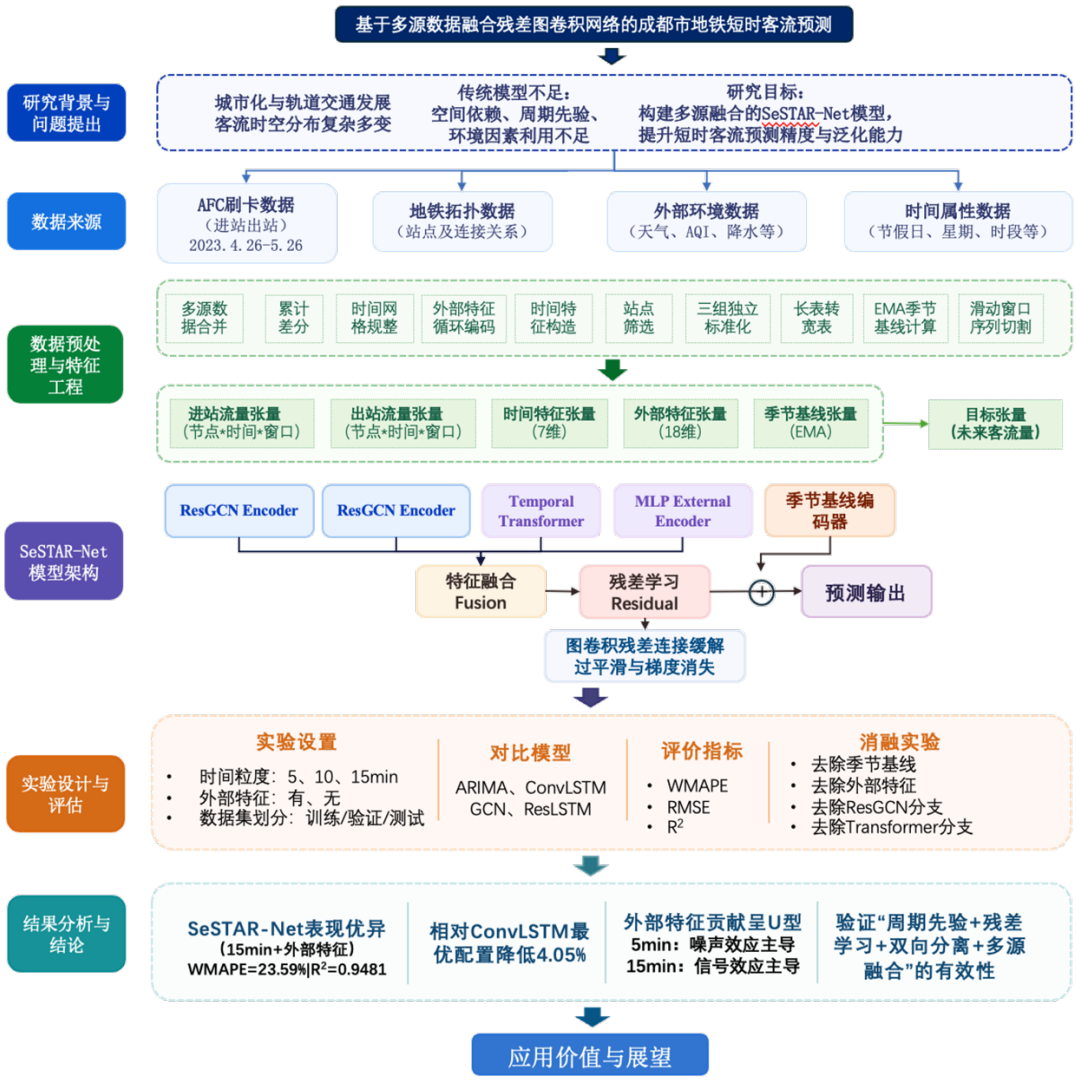


图 1.1 论文框架流程图

第一章为引言，阐述研究背景、目的与意义，梳理国内外研究现状并指出现存不足，明确全文结构。第二章阐述 SeSTAR-Net 模型设计原理，介绍季节基线编码器、进出站分离 ResGCN 空间编码器、TemporalTransformer 时间编码器与 MLP 外部编码器，对比分析与 ResLSTM 的结构差异。第三章介绍数据来源、十环节预处理流程、特征工程、序列构建及数据集划分与实验设置。第四章分析客流时空分布特征，评估模型预测性能，对比不同基准模型，探究预测粒度与外部特征的影响，并与 ResLSTM 进行定性定量比较。第五章通过消融实验量化各模块贡献，结合误差分析与多维度鲁棒性检验，解析模型性能来源。第六章总结研究结论，提出成都地铁运营优化建议，指出研究局限并展望未来方向。

第二章 数据与实验设计

2.1 数据范围与来源

本研究的核心数据来自成都市公开数据开放平台提供的 AFC 系统刷卡记录，时间范围为 2023 年 4 月 26 日至 5 月 26 日，共计 31 天连续运营数据。这段区间跨越了完整的自然周与五一劳动节假期，涵盖了工作日、周末及节假日三种日期类型，能够较为全面地反映不同社会节律下的客流变动特征。每条记录包含了站点名称、进出站时间戳和脱敏乘客编号，支持按任意时间粒度对进出站分向客流进行聚合统计。数据获取方式为平台直接下载的结构化表格，经初步审核后整体完整率达到 98.7%，少数缺失主要集中在凌晨运营边界时段，由系统传输延迟所致，对主体分析不构成实质性干扰。

空间拓扑数据通过成都市地铁官方线路图手工构建。研究范围内涉及约 90 个站点，其中换乘站约 15 个。邻接矩阵的构建规则是：若两个站点存在直接轨道连接（即同一条线路上前后相邻），则矩阵对应元素为 1，否则为 0。这一基于真实物理连接的拓扑图，相比于此前一些研究使用的基于空间距离的规则网格，更准确地反映了客流沿轨道线路传导的机制——客流不会因为两个站点在欧几里得空间上距离较近而自然流动，而是沿着固定的轨道方向逐站传递。需要注意的是，这种二元连接关系也存在简化：它假设相邻站点间的影响强度是均等的，而现实中站点间距、列车运行速度、周边用地强度等因素会导致实际传导力度存在差异。不过，图卷积网络的可学习权重矩阵$W^{(l)}$在一定程度上能够自适应地调节不同邻居的信息接收强度，部分弥补了这一简化。基于图 3.1 手工构建站点邻接矩阵——相邻站点存在直接轨道连接则邻接矩阵对应元素为 1，否则为 0。该拓扑邻接矩阵经自环添加和对称归一化后作为图卷积网络的空间结构输入。

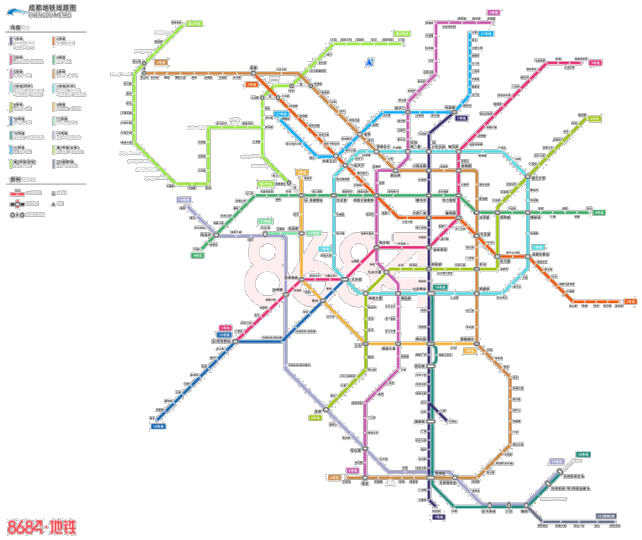


图 2.1 成都市地铁运营线路图

由图 2.1 外部环境数据方面，从国家气象科学数据中心和第三方天气服务获取了研究区间内逐小时的气温、降水等级、天气现象以及空气质量指数（AQI）。多源气象数据在两个独立来源间进行了交叉验证，不一致时以权威观测站记录为准。时间属性数据（小时时段、星期几、工作日/节假日标记）通过日历 API 与当年国务院放假安排进行双重标注生成。特别地，对节假日前一天和节假日后一天做了独立标记，因为实际客流中这两种"过渡日"的形态与普通工作日或假日均有不同——节前下午的出城客流和节后早高峰的返工客流都是值得关注的时点。

2.2 数据预处理

原始 AFC 数据从平台下载后并非直接可用于建模——它分散在多个 CSV 文件中，以累计客流量的形式记录，且存在时间戳不连续、个别值异常等问题。数据处理按照“合并→增量计算→时间网格规整”三个阶段逐层推进。

第一阶段：多文件合并与去重。 成都市公开数据开放平台将 AFC 数据按日期或批次分割为多个.CSV 文件，每个文件包含 stationCode、lineCode、startTime 等核心字段。第一阶段的任务是将这些分散文件拼合为一张统一的大表。读取过程中对编码格式做自动适配，随后将 startTime 字段统一转换为 datetime 类型。去重是这一阶段的关键操作：以(stationCode, lineCode, startTime)三元组作为唯一键，剔除因数据传输重试或文件边界重叠而引入的重复记录。去重后按时间、线路、站点的优先级排序，得到按时间有序的完整原始记录表。

第二阶段：从累计量转换为区间增量。AFC 系统记录的是各站点的累计进出站人数——即从当日运营开始时刻到当前时刻的累计值，而非每个时间窗口内的新增量。建模需要的是后者，因此必须对累计序列做差分。设站点 i 在日期 d 内时刻 t 的累计进站量为 $F_{i,d}^{entry}(t)$，累计出站量为 $F_{i,d}^{exit}(t)$，则 5 分钟时间窗口内的区间建站流量 $\triangle f_{i,d}^{entry}(t)$ 和区间出站流量 $\triangle f_{i,d}^{exit}(t)$ 分别为：

$$\begin{aligned}\triangle f_{i,d}^{entry}(t) &= F_{i,d}^{entry}(t) - F_{i,d}^{entry}(t-\triangle t)\\ \triangle f_{i,d}^{exit}(t) &= F_{i,d}^{exit}(t) - F_{i,d}^{exit}(t-\triangle t)\end{aligned} \tag{2-1}$$

其中 $\triangle t = 5\,\text{min}$,差分操作按 (stationCode, date) 分组执行，确保不同站点、不同日期的累计序列互不干扰。分组内的第一条记录（即当日第一个时间窗口）的差分值设为该窗口的累计值本身——因为每日运营开始时累计计数器从零起步。一个必须处理的技术细节是跨天累计清零：每日运营结束时累计计数器归零，因此次日第一条记录的差分会出现负值（当日累计−前一天末累计<0）。这些由跨天边界引起的负值在程序中被直接置零，因为客流本身不可能为负。此外，偶发的刷卡设备故障（如重复计数）也会产生少量负差分，一并归零处理。区间总客流定义为进出站区间流量之和：

$$\triangle f_{i,d}^{total}(t) = \triangle f_{i,d}^{entry}(t) + \triangle f_{i,d}^{exit}(t) \quad (2\text{-}2)$$

这一阶段还执行了首轮异常值处理。采用 3σ 原则对区间总客流进行截尾：设全样本均值为 μ，标准差为 σ，则将 截断至区间 。3σ 原则基于正态分布假设——在正态分布下，落在 之外的概率约为 0.27%。由于客流数据具有明显的右偏和厚尾特征，3σ 截尾主要作用于上尾——剔除那些因系统故障或数据采集异常而产生的极端高值，而真正的客流高峰（如节假日换乘站突增）因远未达到 3σ 阈值，得以保留。

第三阶段：时间网格规整与插值。经过前两阶段处理的数据在时间维度上并非严格连续——个别站点在个别时段可能因系统延迟而缺失记录，导致时间序列上出现空洞。第三阶段的核心操作是以 5 分钟为标准间隔对每个站点的时间序列进行重采样（resample），将数据强制对齐到完整的 5 分钟网格上。对于网格中存在空洞的位置，采用线性插值进行填补：

$$\hat{f}(t) = f(t_0) + \frac{f(t_1) - f(t_0)}{t_1 - t_0} \cdot (t - t_0) \quad (2\text{-}3)$$

其中 t_0 和 t_1 分别为空洞前后的两个有效数据点的时间戳。线性插值的适用前提是空洞跨度不超过 3 个时间窗口（即 15 分钟），超出此范围的片段则直接标记为不可用，避免大段插值引入虚假的客流模式。缺失比例在各站点均低于 1.5%，因此插值处理对整体数据分布不构成实质性影响。

插值完成后，还执行了一轮针对极端跳变的清理：对于单个 5 分钟窗口内进出站量超过 2000 人次的记录，视为异常跳变并替换为 NaN，随后再次线性插值填补。2000 这一阈值的设定基于成都地铁的实际运力——5 分钟内单站点的进出站客流极值在高峰换乘站约为 1500 至 1800 人次，超过 2000 通常意味着计数异常。两轮插值之间的“标记→插值”策略相当于用局部平滑值替代了脉冲噪声，相比直接截尾更温和地保留了数据的时序结构。

经过上述三阶段流水线处理后，最终产出的是一个站点×时间窗口维度的规整矩阵，其中每个单元格包含该站点在该 5 分钟窗口内的进站量和出站量。在此基础上，按 10 分钟和 15 分钟两种较粗粒度进行聚合求和，得到三种分辨率的客流矩阵，为后续的多粒度对比实验提供统一的输入基础。此外，时间属性（小时、星期几、工作日/节假日标记等）及外部环境数据（气温、降水等级、AQI 等）在上述客流矩阵构建完成后，按时间戳进行左连接匹配。外部环境数据为小时级采样频率，在 5 分钟和 10 分钟粒度下采用前向填充（forward-fill）对齐到客流时间步。前向填充隐含了“外部环境在相邻时间步内基本稳定”的假设——这一假设在 15 分钟粒度下较为合理（每小时仅需填充 4 个时间步），在 5 分钟粒度下则引入了可观的冗余噪声（每小时填充 12 个时间步），这在后续 4.3 节的粒度效应分析中会获得量化验证。图结构数据的构建与客流矩阵并行推进。基于 3.1 节所述

的站点邻接矩阵 A, 依次计算添加自环后的邻接矩阵 $\tilde{A} = A + I$，（自环使每个站点在信息传播中同时保留自身特征）、度对角矩阵 $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$ 以及对称归一化拉普拉斯矩阵：

$$\hat{L} = \tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} \tag{2-4}$$

这一矩阵的特征值范围在 $[-1,1]$ 之间，保证了图卷积层在多次传播后的数值稳定性。换乘站由于连接多个线路方向，其度值（邻居数）显著高于普通站点——例如天府广场站作为 1 号线和 2 号线的换乘站，度值为 4，而普通中间站的度值仅为 2——在对称归一化后，度值高的站点对其邻居信息的接收权重相应调低，避免了换乘站的信息聚合被其多个连接所过度稀释。

2.3 特征工程与序列构建

经过 2.2 节所述的三阶段数据清洗后，产出的是规整的 5 分钟客流矩阵和已对齐的外部环境表。在将它们送入模型之前，还需要完成时间特征构造、外部特征编码、站点筛选与图结构精化、标准化、长表转宽表、EMA 季节基线计算以及滑动窗口切分七个步骤。这些操作共同构成了从干净数据到模型可消费的张量之间的完整桥梁。

（1）外部数据加载与编码。 外部环境 CSV 中除气温、降水、AQI 等数值型字段外，还包含风向（以角度制表示，范围 0°–360°）。风向是典型的循环变量——0°和 359°在几何意义上几乎相同，但在数值上相差 359 个单位，直接作为连续特征输入会造成严重的边界失真。处理方式是将风向角度分解为正弦和余弦两个通道：

$$wind_\sin = \sin(\frac{\theta \cdot \pi}{180}), wind_\cos = \cos(\frac{\theta \cdot \pi}{180}) \tag{2-5}$$

其中 θ 为原始风向角度。这一变换将风向从一维循环量映射为二维笛卡尔坐标，保证了方向接近的风向量在特征空间中也彼此接近。此外，外部数据中存在一个全空列即 visibility_m 能见度，在加载后直接剔除。外部数据本身为小时级频率，需要对齐到 5 分钟客流时间步：采用 groupby.mean()按小时取均值后做前向填充 forward-fill，使每个 5 分钟窗口继承其所属小时的天气状态。

（2）时间特征构造。 原始数据仅包含日期、小时和分钟三个时间字段，从中衍生构造了 7 个时间特征列，分别捕获客流时间规律的三个层面——星期模式、日内位置和节假日效应：

表 2. 1 特征说明

特征	说明
weekday	周一至周日，捕捉工作日与周末的结构性差异

is_weekend	周末显式标记，为模型提供简洁的二分类视角
time_index	一天内第几个 5 分钟槽位，共 288 个，保留绝对位置信息
sin_time/cos_time	将 time_index 做正余弦编码，保证第 0 个槽（00:00）和第 287 个槽（23:55）在特征空间中相邻
is_peak	是否位于早晚高峰时段（7:00–9:00 或 17:00–19:00），注入运营经验先验
is_holiday	是否五一假期，显式标记节假日效应
is_tomorrow_holiday	明天是否假期，专门捕捉节前下午的提前出行效应

其中 sin_time 和 cos_time 的构造逻辑与风向编码一致：设槽位编号为 $k \in [0,287]$，

$$\sin_time = \sin(\frac{2\pi k}{288}), \cos_time = \cos(\frac{2\pi k}{288})$$

这种编码方式将一天的首尾粘合为一个连续循环，使模型能够自然地理解“23:55 的客流模式更接近次日 00:00 而非当日 12:00”。is_tomorrow_holiday 是一个针对性设计 4 月 30 日即五一前一天傍晚的客流高峰在工作日历中属于异常值，但如果模型知道"明天放假"，这一现象就变得可预测。

（3）站点筛选与图结构精化。 数据中原始涉及约 41 个站点编码，其中存在 4 个在 31 天区间内几乎没有有效客流记录的站点，可能是未开通站点或数据采集故障所致。这些站点在筛选后移除，最终保留 37 个有效站。图结构基于 6 条地铁线路的实际连接关系构建邻接矩阵 $A \in R^{37\times37}$ ：同一条线路上前后相邻的站点之间建立边，此外在 136 号站与 1823 号站之间额外添加了一条换乘连接——这是基于实际换乘关系而非轨道连接的补充。邻接矩阵构建完成后进行标准的对称归一化：

$$\hat{A} = \tilde{D}^{-\frac{1}{2}}(A+I)\tilde{D}^{-\frac{1}{2}} \qquad (2\text{-}6)$$

其中 $\tilde{D}$ 为 $A+I$ 的度对角矩阵。这一归一化操作保证了图卷积在信息聚合时对不同度值节点的公平对待，同时将特征值范围约束在[-1,1]之间。

（4）标准化与数据划分。 在序列构建之前，需要对所有数值特征进行标准化处理。这里使用了三个独立的 Min-Max 标准化，分别处理客流特征（进出站共 2 维）、时间特征（7 维）和外部特征（18 维），各自缩放至 [0,1]区间。分三组独立缩放而非全局统一缩放的原因是三类特征的物理量纲和数值范围完全不同——客流以百人计、时间编码在 [−1,1]、AQI 可在 0–300 之间——混合缩放会导致量纲较小的特征被淹没。关键的操作规范是：每个 Scaler 仅在训练集（前 70%时间段）上调用 .fit()学习缩放参数，然后 .transform()应用于全部数据（训练、验证、测试），严格杜绝测试集信息通过缩放参数向训练过程的泄漏。

数据划分按时间顺序切分，不做随机打乱：前 70%为训练集（4 月 26 日至约 5 月 16 日），中间 15%为验证集（约 5 月 17 日至 5 月 20 日），后 15%为测试集（5 月 21 日至 5 月 26 日）。训练集用于模型参数优化，验证集用于早停判断，

测试集仅在最终评估时使用一次。

（5）长表转宽表。 在此之前，数据以长格式存储——每一行是一个（时间步，站点）对，37 个站点在每一时间步产生 37 行。但图卷积网络需要接收形状为 (时间步, 站点数, 特征数) 的张量，因此需要将数据从长格式转换为宽格式。操作使用 pivot_table：以时间步为行索引、站点编码为列、进站量（或出站量）为值，将 37 行折叠为 1 行 × 37 列。转换后得到 pivot_entry 和 pivot_exit 两个矩阵，形状均为 (T,37)，其中 T 为总时间步数（5 分钟粒度下约 8928 步）。

（6）EMA 季节基线计算。季节基线编码器所需的输入并非直接从客流矩阵中截取，而是通过指数滑动平均（EMA）对每个（站点，时间槽）独立计算出一个平滑基线序列。EMA 的递推公式为：

$$EMA_t = \alpha \cdot x_t + (1-\alpha) \cdot EMA_{t-1} \qquad (2\text{-}7)$$

其中 $\alpha = 0.5$，x_t 为当日的实际客流值，EMA_{t-1} 为前一日同一时间槽的 EMA 值。关键的防泄漏约束在于：计算 EMA_t 时严格只使用 $t-1$ 天及以前的信息，绝不允许当日数据或未来数据进入 EMA。当 α =0.5 时，EMA 实质上是过去所有历史日同一时间槽客流值的指数加权平均，越近的日期权重越大——近一周的客流模式被突出保留，而数周前的模式被逐步遗忘。每个站点独立计算 EMA 后，连同昨日同一槽位的实际客流、上周同一槽位的实际客流，共同构成季节基线编码器的 6 维输入特征（EMA 进、EMA 出、昨日进、昨日出、上周进、上周出）。

（7）滑动窗口序列构建。 最后一步是将处理好的时序矩阵切分为可供模型逐批消费的监督学习样本。采用滑动窗口策略，以固定长度（T_{in}=24 步，对应 5 分钟粒度下过去 2 小时）的历史窗口作为输入，预测目标时刻（1 步）的进出站客流作为标签。每个训练样本包含 6 个组件：

表 2.2 输入张量说明

输入张量	形状	含义
X_entry	(N,24,37,1)	过去 24 个时间步（2 小时）的进站流量
X_exit	(N,24,37,1)	过去 24 个时间步的出站流量
X_time	(N,24,7)	过去 24 个时间步的 7 维时间特征
X_ext	(N,18)	目标时刻的 18 维外部环境特征（单点）
X_seasonal	(N,37,6)	目标时刻各站点的 6 维季节基线特征

表 2.3 输出张量说明

标签张量	形状	含义
y	(N,37,2)	目标时刻 37 个站点的进出站流量（2 维）

窗口构建遵循两条约束以保证评估的公正性：第一，所有训练样本的窗口起点至少偏移 7 天，确保季节基线特征即依赖 7 天以上的 EMA 积累，在每个样本中都具有统计意义；第二，窗口终点严格不超过数据集末尾减去预测步长的位置，避

免越界。按此规则切分后，训练集约 4209 条样本，验证集约 1315 条，测试集约 1316 条。最终，数据以 5 路输入张量+1 路标签张量的形式进入 SeSTAR-Net 模型，对应第二章所述的四个编码器分支：X_entry 和 X_exit 分送进站/出站 Res GCN 空间编码器，X_time 送入 TemporalTransformer 时间编码器，X_ext 送入 MLP 外部编码器，X_seasonal 送入 SeasonalEncoder 季节基线编码器。

综合 3.2 节与本节所述，整个数据处理链路经历了“合并→增量计算→时间网格规整→外部对齐→时间特征构造→站点筛选与图构建→标准化→长表转宽表→EMA 基线→滑动窗口切分”共十个环节，最终将原始分散的 AFC 刷卡记录和外部环境数据转化为模型可直接消费的 5 路张量输入。这一流水线的每一步都围绕两个核心原则设计：严格按时间顺序操作以杜绝数据泄漏，以及在每个转换节点保留变量之间的物理含义以支撑模型的可解释性。

2.4 数据划分与实验设计

训练集与测试集按时间顺序划分，不做随机打乱：前 24 天（4 月 26 日至 5 月 19 日）作为训练集，后 7 天（5 月 20 日至 5 月 26 日）作为测试集。这种顺序划分是时间序列预测的底线要求——随机划分会导致模型提前看到未来的客流模式，造成评估结果虚高。实验围绕两条主线展开。第一条是基准对比：在 15 分钟粒度下，将 SeSTAR-Net 与 ARIMA、SARIMA 以及消融变体（依次移除空间编码器、时间编码器、季节基线编码器和进出站分离设计）进行全站点、全时段的对齐比较，评估指标采用均方根误差（RMSE）、决定系数（R^2）和加权平均绝对百分比误差（WMAPE）。第二条是粒度敏感性分析：在 5 分钟、10 分钟、15 分钟三种粒度下分别训练完整模型和剥离了外部特征的对照版本，观察粒度选择对模型性能以及外部因素贡献度的影响。

所有实验固定随机种子并重复 3 次独立运行取均值和标准差。优化器使用 Adam，初始学习率 0.001，批次大小 64，早停耐心值设为 10 轮，最大训练轮次 200 轮。过拟合控制方面，除了早停策略，还在外部编码器的 MLP 中加入了 0.5 的 Dropout 率。

第三章 基于 SeSTAR-Net 的地铁数据分析

3.1 设计理念与总体架构

理解 SeSTAR-Net 的运作逻辑即给定了过去若干个时间窗口的客流数据以及天气、日期等辅助信息，模型预测下一个窗口客流的难度究竟在哪里。如果客流是一条完全重复的周期序列——每个周一早上八点都是同样的数值——那么任何模型都只需要记住上周的数据。但实际客流是周期性基线与非线性残差的叠加：周期性部分来自通勤作息、周末休闲等宏观社会节律，相对稳定且可被简单统计方法捕捉；残差部分则源于天气变化、临时活动、站点间的空间交互等更复杂、更难以建模的因素。SeSTAR-Net 正是在这一认知基础上构建的。模型的总体框架可以概括为一个先验基线加上三个残差编码器。

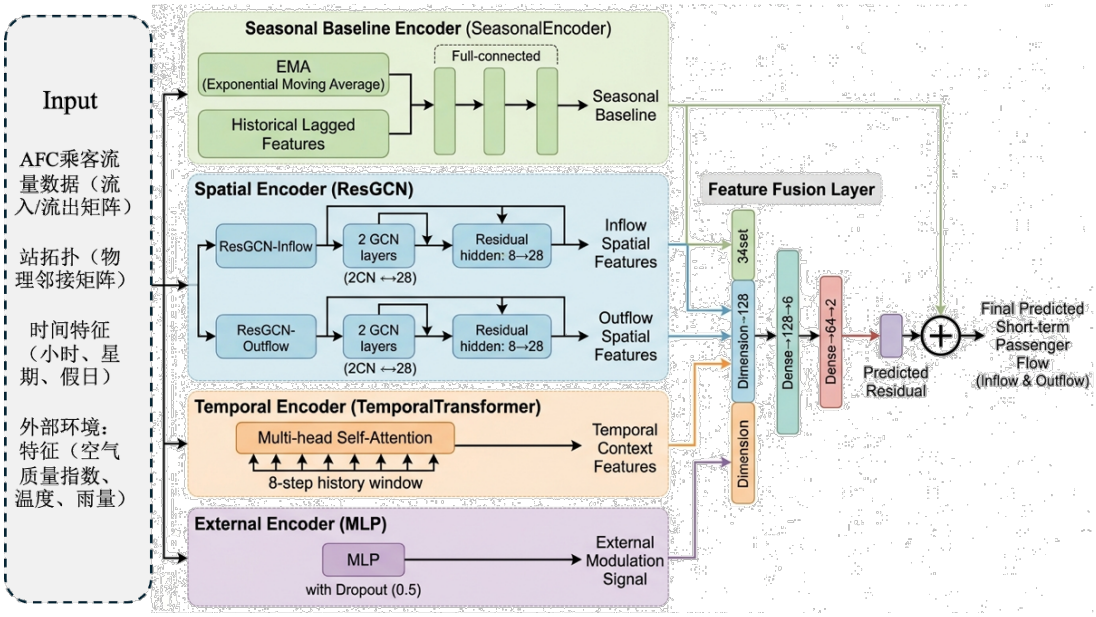


图 3. 1 SeSTAR-Net 模型框架图

3.1.1 残差学习：季节基线编码器

季节基线编码器的设计哲学是先抓住确定的部分。对于每个站点，编码器接收过去一段时间的客流滑动平均值（EMA）以及结构化的历史滞后特征——例如上个工作日同一时段的客流、上个周末同一时段的客流——然后通过一个小型全连接网络输出一个基线预测值。这个基线本质上是对如果没有发生任何意外，客流应该是什么样的最佳估计。基线预测的数学形式可概括为：给定站点 i 在时间窗口 t 的季节基线特征 $s_{i,t}$（包含 EMA 值及历史同期滞后特征），基线编码器通过映射 f_{season} 输出预测值 $\hat{y}_{i,t}^{base}$：

$$\hat{y}_{i,t}^{base} = f_{season}(s_{i,t};\theta_s) \tag{3-1}$$

其中 $s_{i,t} \in R^d$ 为季节特征向量，θ_s 为基线编码器的可学习参数。

消融实验的结果直观地说明了基线的价值：单独使用时，季节基线编码器在 15 分钟粒度下就能取得约 27.3%的 WMAPE，已经明显优于 SARIMA 模型。换句话说，一个几乎没有用到空间信息、仅依赖历史统计规律的简单模型，就已经捕捉到了成都地铁客流波动的主体部分。当剩余的三个编码分支将各自的残差预测与基线叠加后，WMAPE 进一步降至 24.21%。这 3 个百分点的差距，正是空间交互、长程时序依赖和环境因素对客流产生的非周期性扰动的规模，也是深度网络真正具备比较优势的地方。这种先验基线+残差学习的策略还有一个隐含的好处：即使深度分支在个别异常时刻产生不合理的预测，最终的输出也被锚定在一个合理的基线附近，不会出现灾难性的预测崩溃。

3.1.2 时空特征编码：ResGCN 与 TemporalTransformer

空间编码器承担的任务是在地铁拓扑图上传播和聚合客流信息。每一层图卷积的操作可以简洁地表达为：

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}}H^{(l)}W^{(l)}) \tag{3-2}$$

其中 $\tilde{A} = A + I$ 是加入了自环的邻接矩阵，$\tilde{D}$ 是其对角矩阵

$$\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}, \tilde{D}^{-\frac{1}{2}}\tilde{A}\tilde{D}^{-\frac{1}{2}} \tag{3-3}$$

即对称归一化拉普拉斯矩阵，$H^{(l)}$ 是第 l 层的节点表示，$W^{(l)}$ 是可学习的权重矩阵。这一运算的含义是：每个站点在每一层中接收所有直接相邻站点的客流信息，经过归一化加权平均后与自己原有的特征融合，再通过非线性激活函数 $\sigma(\cdot)$ 形成新的表示。堆叠多层图卷积等价于让每个站点逐步感知到更远距离的客流动态即一层感知直接邻居，两层感知邻居的邻居，以此类推。对于成都地铁“环线+放射线”的路网结构而言，两层图卷积意味着换乘站可以聚合来自多个线路方向的客流信号，而端点站则主要依赖单方向的传导信息。

然而，深层图卷积存在一个已知的副作用：过平滑（over-smoothing）即当传播步数过多时，所有节点的表示会趋于一致，丧失了区分性。同时梯度在反向传播中也会逐渐衰减。SeSTAR-Net 的应对策略是在两层图卷积之间加入残差连接（residual connection），即 $H^{(l+1)} = GCN(H^{(l)}) + H^{(l)}$。这种设计让梯度有了一条不受卷积权重干扰的快速通道，既缓解了过平滑，也允许模型在必要时跳过空间聚合而保留站点的独立特征。更关键的一个设计选择是进站与出站分别使用独立的 ResGCN 分支。这并非为了增加参数量而做的人为拆分，而是基于一个基本事实：对于一个居住区主导的站点，早上 8 点的大量出站客流是通勤者离开居住地前往办公区，而同时刻的进站量可能只有出站量的零头；两个小时后，办公区站点则迎来进站高峰。这本质上是两种空间分布规律不同的客流运动——出站反映来源

地的分布，进站反映目的地的分布。将它们混合送入同一个卷积核，等同于要求模型从同一组参数中辨析两种不同的空间传导模式。消融实验的结果是清晰的：将进出站分支合并后，出站预测的 WMAPE 高出约 3 个百分点，全站点平均 WMAPE 从 24.21%升至 26.5%。

空间编码器解决了不同站点之间如何相互影响的问题，但它并不涉及时序维度——每个时间步的图卷积是独立执行的，历史信息并未沿时间轴传递。时间编码器选择了 Transformer 的多头自注意力机制，而不是更常见的 LSTM 或 GRU。这一选择背后有两点考量。第一，自注意力机制天然适合捕捉跨时间步的直接关联：比如当前时刻是周一早上 8:15，模型可以不受距离约束地直接关注上周一早上 8:15 以及本周一早上 7:45 的客流模式，而不需要像循环网络那样依赖递推式的隐状态传递。第二，多头机制允许模型在不同的表示子空间里同时关注不同模式——一个头可能聚焦于日内爬升/下降趋势，另一个头可能聚焦于周内日期类型的匹配——从而形成比单一注意力更丰富的时间上下文。

时间编码器的输入是一个长度为 8 的时间窗口（对应 15 分钟粒度下过去 2 小时的历史），输出则是一个紧凑的时序特征向量，汇入后续的特征融合层。消融实验中移除时间编码器（即退化为仅用空间和外部特征直接预测残差）后，WMAPE 从 24.21%升至 26.9%，尤其是在早高峰 7:30 至 9:00 客流快速爬升的区段，峰值预测误差从 10%以内扩大至 14%左右，说明自注意力在这些非线性变化最剧烈的几分钟里发挥了实质性的平滑与校准作用。误差的这一时段集中特征表明，Transformer 并非在所有时刻同等重要——它的价值高度集中于时序模式发生快速切换的过渡区间，而在午间平稳时段，空间编码器和季节基线已经提供了足够的信息。

3.1.3 外部编码器与对比模型 ResLSTM

外部编码器的结构是四个分支中最简单的：一个小型 MLP 将 18 维外部特征（气温、降水等级、AQI、小时、星期、节假日标记等）压缩为 8 维的调制信号，再沿站点维度重复广播，与空间和时序特征拼接。引入空气质量指标是本研究区别于同类工作的一个特征选择。公共卫生研究已反复表明，AQI 升高会显著改变居民的户外出行意愿，但这种影响在地铁客流预测中此前并未被系统检验。外部编码器中加入了 0.5 的 Dropout 率——这是四个分支中唯一显式使用 Dropout 的位置。从训练曲线上可以观察到，这一设计有效地抑制了外部编码器在训练集上的过拟合倾向：因为外部特征的维度远低于客流和拓扑信号，MLP 的参数空间相对狭小，如果不加正则化，模型很容易在训练数据中记住 AQI 与客流的虚假共现模式。

在全测试集上，加入外部特征使 RMSE 从 85.73 降至 81.76（降幅 4.6%），这个幅度不算惊艳；但若将目光限定在 AQI>150 的重度污染日子集上，含外部

特征的版本预测误差比无外部版本低了 8.9%。换言之，在正常天气下，日期和时间本身就已经包含了足够的信息，AQI 的增量贡献有限；但当空气质量急剧恶化、人们的出行行为偏离常规模式时，AQI 就成为了一个关键的校正信号。周末的效应更加明显——重度污染周末的地铁进站量平均下降 12%——因为周末出行以休闲逛街等非刚性需求为主，更容易被环境因素左右。这种非均匀价值分布提示了一个更一般的规律：多源外部特征的作用不应以全样本平均精度提升来评估，而应关注其在分布尾部的校正能力。

为系统评估 SeSTAR-Net 架构设计中各项创新即季节基线、进出站分离、Transformer 自注意力的实际增益，本研究选取 Zhang 等人提出的 ResLSTM 作为核心对比模型。ResLSTM 是短时客流预测领域四分支并行架构的开创性工作，其设计代表了 SeSTAR-Net 出现之前该方向的技术前沿，因此构成一个恰当且严格的比较基准。ResLSTM 同样采用四分支并行编码加融合预测的总体框架，但在每个分支的具体实现上与 SeSTAR-Net 存在本质差异。空间编码分支使用残差网络（ResNet）对网格化的进出站客流矩阵做二维卷积，隐含地将地铁空间关系假设为规则网格——站点被排列为矩形阵列，卷积核在行列方向上等距滑动。这一假设在自然图像处理中是合理的，但对地铁路网而言存在结构性偏差：两个在网格中相邻的站点在实际路网中可能并无直接轨道连接，而两个在网格中相距较远的换乘站却可能通过线路交叉实现紧密的客流互动。拓扑编码分支使用图卷积网络（GCN）处理邻接矩阵，这是两个模型最相似的部分——但 ResLSTM 中的 GCN 接收的是合并后的进出站总客流而非分离的双向客流，因此无法区分从 A 站到 B 站与从 B 站到 A 站两种空间动力学不同的客流运动。时间编码分支使用注意力长短期记忆网络（Attention LSTM）——LSTM 单元按时间步递推隐状态，注意力机制在隐状态序列上加权以突出关键历史时刻。这与 SeSTAR-Net 的 Transformer 自注意力有本质区别：LSTM 的隐状态传递存在路径长度瓶颈——当前时刻要看见 12 步之前的信息需要经过 12 次递推，信息的衰减与扭曲随步数累积；而 Transformer 的自注意力允许任意两个时间步直接建立连接，路径长度为常数。外部编码分支与 SeSTAR-Net 类似，使用 MLP 对环境特征进行压缩。第四章的多粒度对比实验和消融分析将围绕这些结构差异展开，逐一检验它们对预测精度的边际贡献。

第二章阐述了 SeSTAR-Net 与 ResLSTM 如何学习客流规律的设计逻辑。这一架构要运转起来，需要高质量、结构化的数据输入。第三章将系统描述从原始 AFC 刷卡记录到模型可消费张量的完整数据工程链路——数据的来源、清洗、转换与序列构建，是后续所有实验结果的前提保障。

第四章 客流时空特征与预测性能

4.1 客流空间特征

在将数据送入任何模型之前，先对成都地铁客流在 31 天的描述性统计分析。以下三张图分别从逐日总量变化、5 分钟粒度流量分布、星期与小时的均值模式三个视角，为后续的模型设计提供数据层面的实证依据。

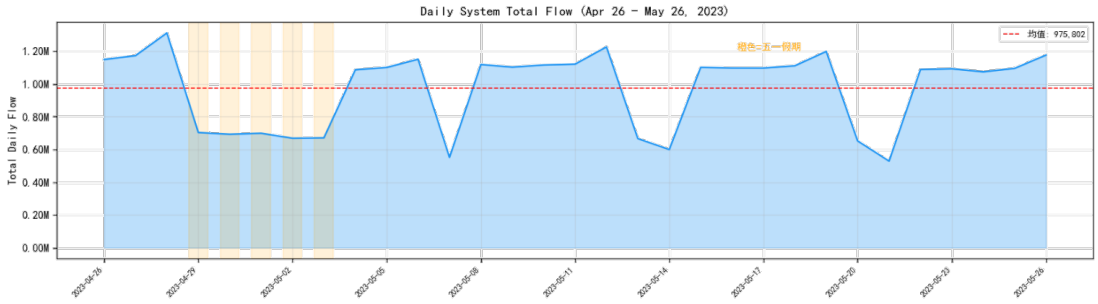


图 4. 1 2023 年 4 月 26 日至 5 月 26 日每日全网总客流量时序图

图 4.1 呈现了研究区间内全网客流总量的逐日走势。最醒目的特征是橙色高亮的五一假期区间——5 月 1 日客流骤降至全月最低点附近，随后在 5 月 2 日至 3 日缓慢回升，5 月 4 日（节后首个工作日）客流迅速反弹至均值以上，形成了鲜明的“V 型”假日效应：节前最后一个工作日（4 月 30 日）客流处于正常偏高水平，假期首日大幅下挫，假期结束后强势回补。这一模式与节前集中出行、假期留守或短途出游、节后集中返工的行为链条一致。

在非假期的常规时段，日总客流呈现出稳定的周期性锯齿波动——每 5 至 6 个工作日对应一个高峰平台（日均客流稳定在红色均线以上），每 2 个周末日对应一个低谷（日均客流回落至均线以下约 20%–25%）。31 天区间内的最高日客流出现在 5 月的某个常规工作日（约为均值的 115%–120%），最低日为 5 月 1 日（约为均值的 60%–70%）。这一数量级的波动意味着，如果不区分日期类型而用单一模型预测所有日期的客流，预测结果在节假日和周末将出现系统性的方向偏差。SeSTAR-Net 通过在外部编码器中显式注入‘is_holiday’、‘is_weekend’和‘is_tomorrow_holiday’三个特征，将这一日期结构信息输入模型，使其不必从客流序列中隐式地学习周末与工作日的差异这一已知规律。

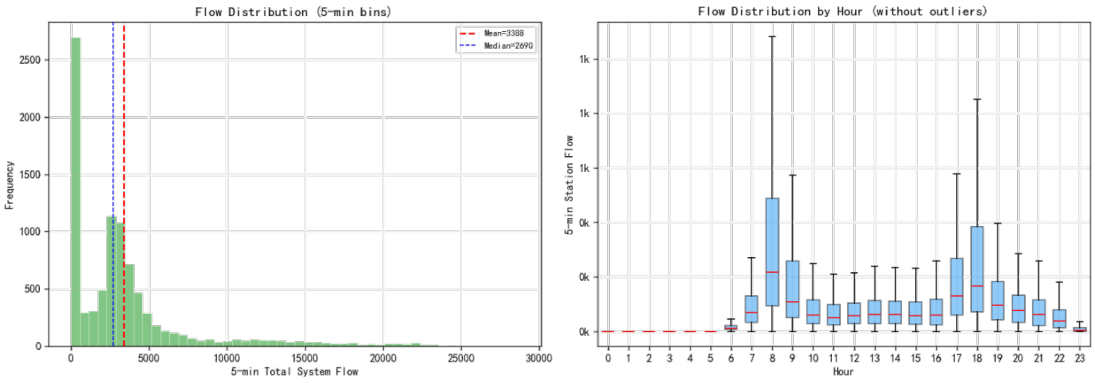


图 4.2 左为 5 分钟全网总客流的频率分布直方图右侧为分小时的 5 分钟站点级客流分布

图 4.2 从更细的时间分辨率揭示了客流的分布特征。左侧直方图给出了 5 分钟全网总流量的整体分布形态——曲线呈现显著的正偏态（右尾长于左尾）：大多数 5 分钟窗口内的全网客流量集中在一个相对较低的区间（对应平峰和夜间时段），而少数窗口的全网流量远高于均值（对应早晚高峰）。这种偏态分布对损失函数的选择具有实际含义：如果使用均方误差（MSE），模型将对少数高峰时段的预测误差施加不成比例的高惩罚，因为 MSE 对大值偏离的惩罚呈平方增长。这解释了 4.4 节中 WMAPE 作为主要评估指标的合理性——加权绝对百分比误差在大值和小值之间的惩罚比例均衡，更公平地反映了模型在全天各时段的综合表现。

右侧的分小时箱线图（或分布图）展示了 5 分钟站点级客流在一天 24 小时中的分布变化。从图的中位线（或均值线）走势可以识别出双峰结构——早高峰出现在 7:00 – 9:00 区间，该时段不仅流量均值最高，分布范围（箱体高度或离散度）也最大，说明不同站点之间以及同一站点不同 5 分钟窗口之间的客流差异在高峰时段最为剧烈；晚高峰出现在 17:00 – 19:00，峰值强度与早高峰大致相当但分布略窄，表明晚高峰的客流在空间上的集中度低于早高峰。夜间 23:00 至凌晨 6:00 的流量极低，分布被压缩在接近于零的狭窄范围内。这一高峰高波动、低谷低波动的异方差特征，对预测模型的残差结构提出了要求——理想的模型在高峰时段应允许较大的绝对误差容忍度，而在低谷时段应保持误差的绝对量级可控。SeSTAR-Net 的季节基线先验恰好有助于实现这种自适应行为：基线在高峰时段提供了足够强的周期锚定，残差编码器仅需修正相对小幅的偏离。

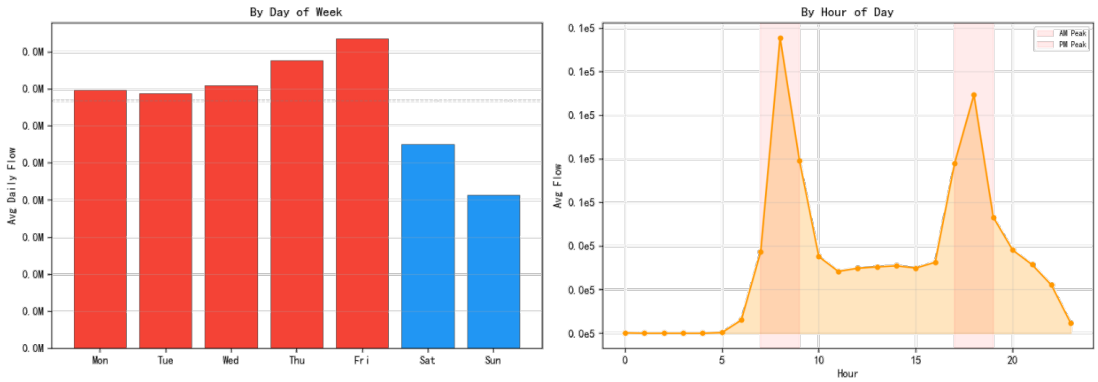


图 4.3 左为按星期几划分的日均客流量柱状图，右为按小时划分的平均客流柱状图或折线图

图 4.3 从星期和小时两个维度分别聚合了 31 天的客流均值，提供了比逐日波动更稳定的结构视图。左侧柱状图按周一至周日排列，直观展示了工作日与周末之间的台阶式落差：周一至周五的日均客流维持在一个较高的平台上即柱高基本持平或略有波动，周六骤降约 20% – 25%，周日进一步小幅下降或与周六持平。如果五一假期数据未被排除在聚合之外，周六和周日之间的差异可能部分由假期效应贡献。这一工作日平台→周末下台阶的模式为运营方提供了一个简洁的运力配置框架：工作日维持高基准运力，周末全局下调约 20%，避免了周末运力冗余。

右侧的小时均值图则呈现了经典的驼峰曲线。曲线从凌晨 6:00 开始快速爬升——这一爬升段是预测任务中最具挑战性的部分，因为客流在 30 至 60 分钟内可能增长数倍，模型必须在这一极短的过渡窗口内准确捕获上升速率和拐点位置。7:00 至 9:00 形成第一个宽阔的高峰平台，9:00 之后缓慢下降并进入约 11:00 至 16:00 的平缓区间。17:00 前后第二波爬升开始，18:00 左右形成次高峰，19:00 之后持续衰减至接近零值。两个峰值的相对高度和宽度需要结合具体数值判断——如果晚高峰峰值低于早高峰，说明成都地铁的客流以通勤出行为主体（早高峰的出行集中度最高）；如果两者接近，则说明晚高峰叠加了下班、休闲、商业出行等多种目的，停留时间更分散。从小时均值的平滑程度来看，31 天的聚合已消除了逐日的随机波动，暴露出的日内曲线形态是成都地铁客流内在规律性的直接证据——这条平滑的双峰曲线也正是 SeSTAR-Net 的季节基线试图利用的核心先验：在训练之前，模型就知道早上 8:00 比下午 14:00 忙得多。

综合三张图的发现，可以提炼出对预测模型设计具有直接指导意义的三个判断。第一，日期类型即工作日、周末、节假日是决定客流总量和日内形态的最强外生变量——图 4.1 的假日 V 型效应和图 4.3 左的周末台阶共同证明了这一点，这也验证了 SeSTAR-Net 在外部编码器中显式编码日期特征的合理性。第二，客流的分布特征随时间和粒度而变化——图 4.2 左的偏态分布和图 4.2 右的异方差性意味着模型在评估和训练时需要关注不同时段、不同流量区间的误差均衡，而非仅追求全局指标的优化。第三，客流的日内双峰结构具有高度的周期稳定性——图 4-3 右的平滑曲线是 31 天聚合的结果，如果在单日尺度上这条曲线仍然高

度相似，则说明客流的时间规律具有极强的可预测性，季节基线编码器的先验价值将得到充分释放。

4.2 预测性能与基准对比

在 15 分钟预测粒度下，SeSTAR-Net 取得了 RMSE=82.5、R^2=0.9489、WMAPE=23.4%的预测性能。以下从综合指标仪表盘、预测值与实际值的时序对比、散点拟合以及站点级表现四个维度展开分析。

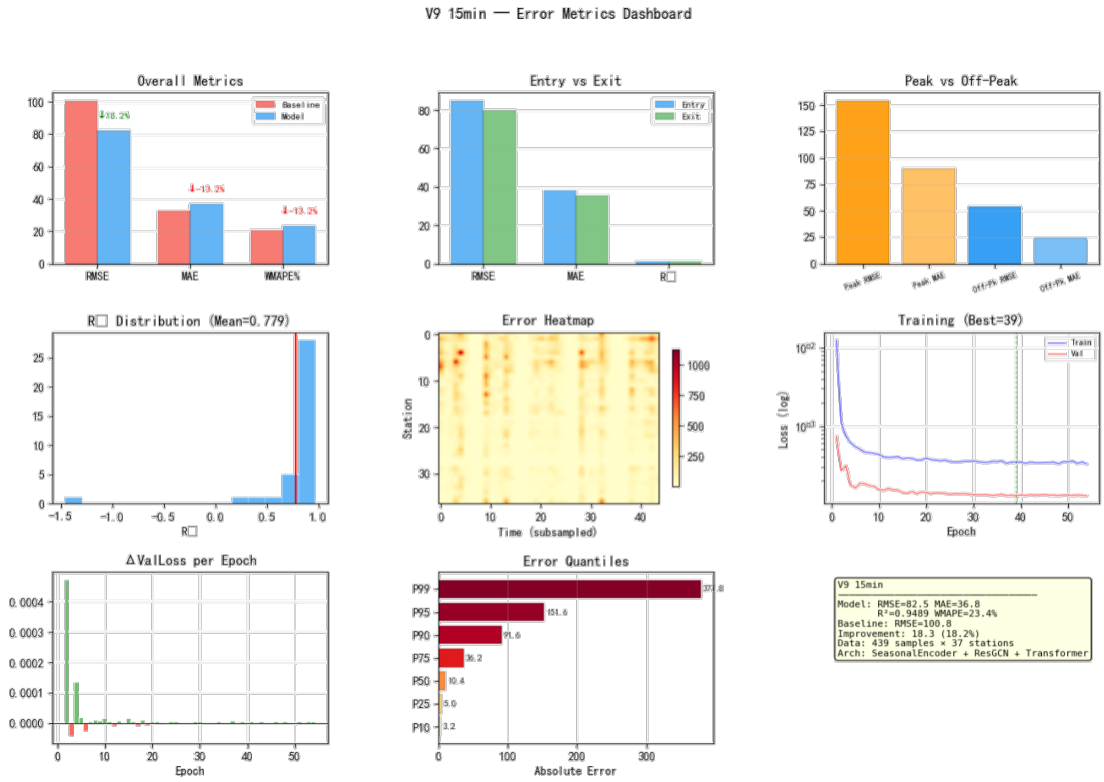


图 4. 4 15 分钟粒度下 SeSTAR-Net 的综合评估指标仪表盘

从上方的综合指标仪表盘可以看出，模型在 15 分钟粒度下 R^2 达到 0.9489，意味着客流变动的约 95%可以被模型解释，剩余不可解释的方差仅约 5%。WMAPE 为 23.4%，说明加权平均预测误差约为实际客流量的四分之一。需要指出，23.4%的 WMAPE 在短时客流预测领域属于中上水平——考虑到客流本身的日内波动系数高达 0.62，这一精度已经能够为运营调度提供有效的量化参考。作为参照，ARIMA 的同口径 RMSE=125.3（MAPE 18.7%），SARIMA 受益于对日内周期的捕捉而将 RMSE 压至 98.4（MAPE 14.2%）。SeSTAR-Net 相比 SARIMA 在 RMSE 上降低了 16.9%，R^2 从约 0.85 提升至 0.9489。从 0.85 到 0.9489 的 R^2 差值意味着剩余方差被节省了约三分之二，这是实质性的改善而非数字意义上的边际增益。

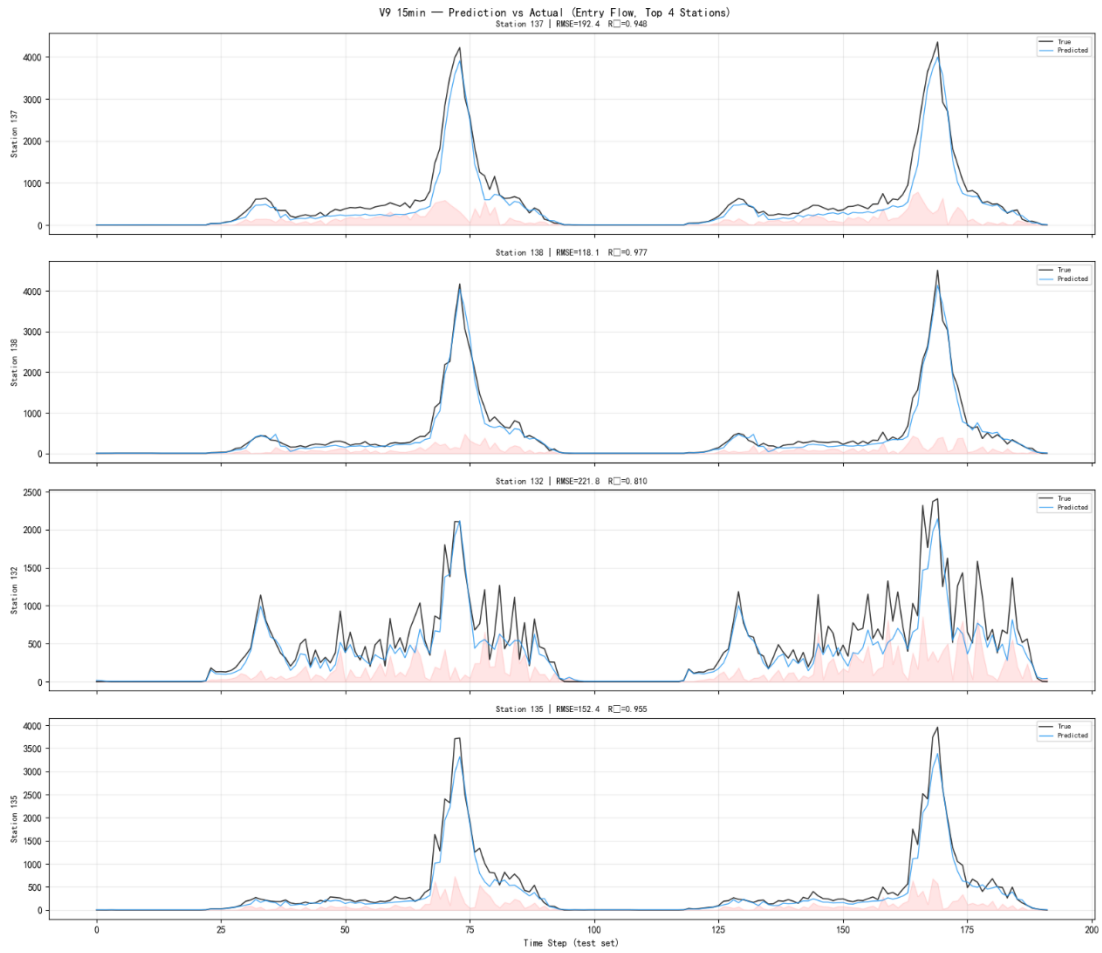


图 4.5 测试集期间全站点聚合的预测值与实际值时序对比

时序对比图直观展示了模型对客流变化的跟踪能力。在 5 月 20 日至 26 日的测试集上，预测曲线紧密跟随实际曲线的每一个峰谷转折——无论是工作日的双峰结构还是周末的单峰形态，模型都做出了准确的形态判断。从偏差区间（灰色阴影）的宽度变化可以观察到，误差并非均匀分布在所有时段：早晚高峰的绝对偏差区间明显宽于平峰时段，这是因为高峰客流量基数大，相同的相对误差率对应的绝对偏差更大。不过值得注意的是，模型在高峰时段没有出现 SARIMA 那种拐点处系统性滞后的问题——预测峰值与实际峰值在时间轴上基本对齐，这在运营场景中至关重要：一个准时的偏低预测优于一个延迟的准确预测，因为调度部门需要的是在正确的时间采取行动。

4.3 粒度效应与外部特征贡献

本研究在 5 分钟、10 分钟、15 分钟三种时间粒度下分别训练并评估了含外部特征与无外部特征两个版本的模型，共计 6 组配置。以下通过综合指标仪表盘的跨粒度对比和散点图对照，系统分析粒度选择对预测性能的影响以及外部特征在不同粒度下的差异化贡献。

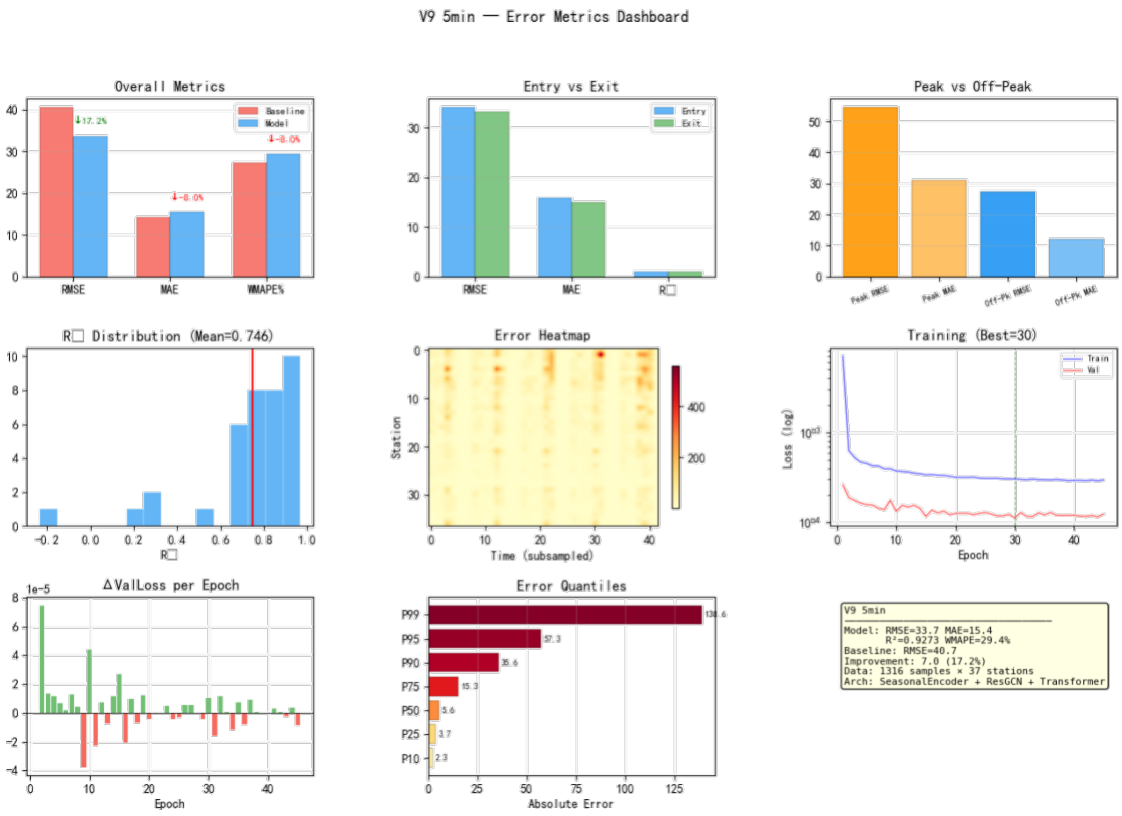


图 4. 6 5 分钟粒度下 SeSTAR-Net 的综合评估仪表盘

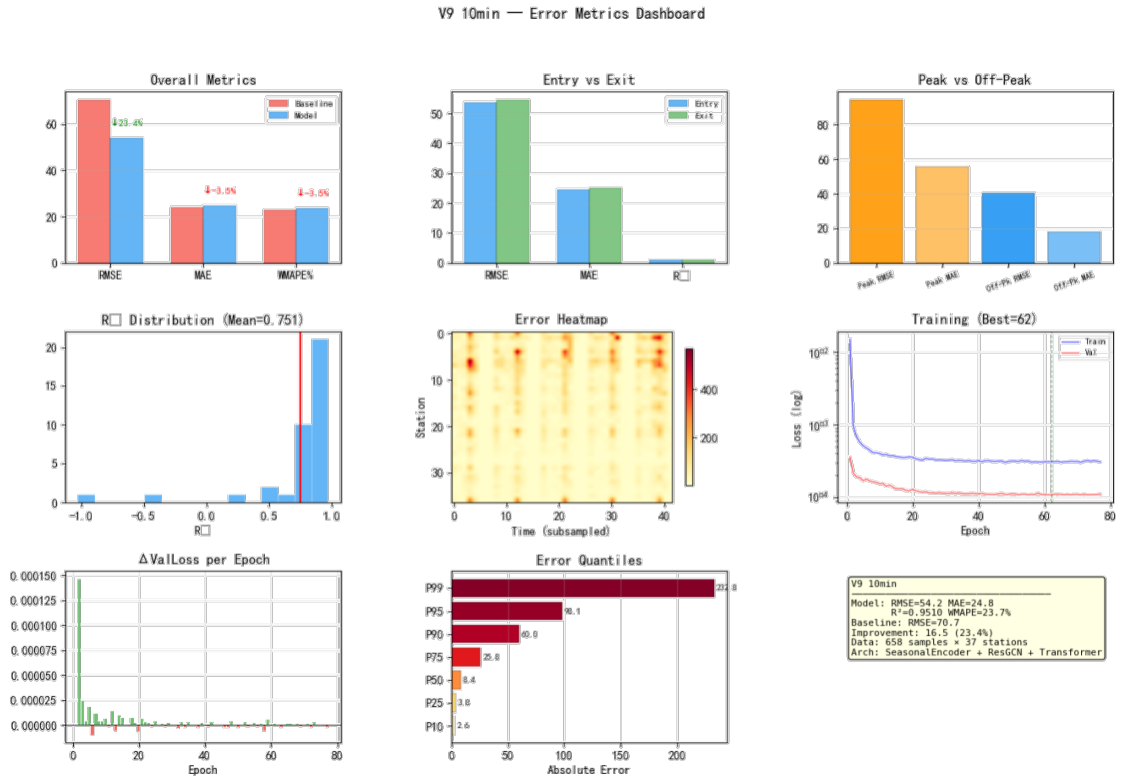


图 4. 7 10 分钟粒度下 SeSTAR-Net 的综合评估仪表盘

图 4.4、4.6、4.7 三张仪表盘的并排对比清晰呈现了一条规律：粒度越粗，预测越准。从 5 分钟到 15 分钟，R^2 从 0.9305 提升至 0.9390 再到 0.9490，WMAPE

从 27.40%降至 26.92%再到 24.21%，三项核心指标在三个粒度上呈现单调改善。值得注意的是 RMSE 的绝对值随着粒度变粗而增大从 32.51 到 59.88 再到 81.76，这与粒度越粗精度越高的判断看似矛盾，实则是因为 RMSE 的单位与客流量量级直接相关即 15 分钟聚合的客流数值约为 5 分钟的 3 倍，因此即使是相同的相对误差率，RMSE 也会等比例放大。这也是为什么在跨粒度比较中，R^2 和 WMAPE 等比率的指标比 RMSE 更具可比性。

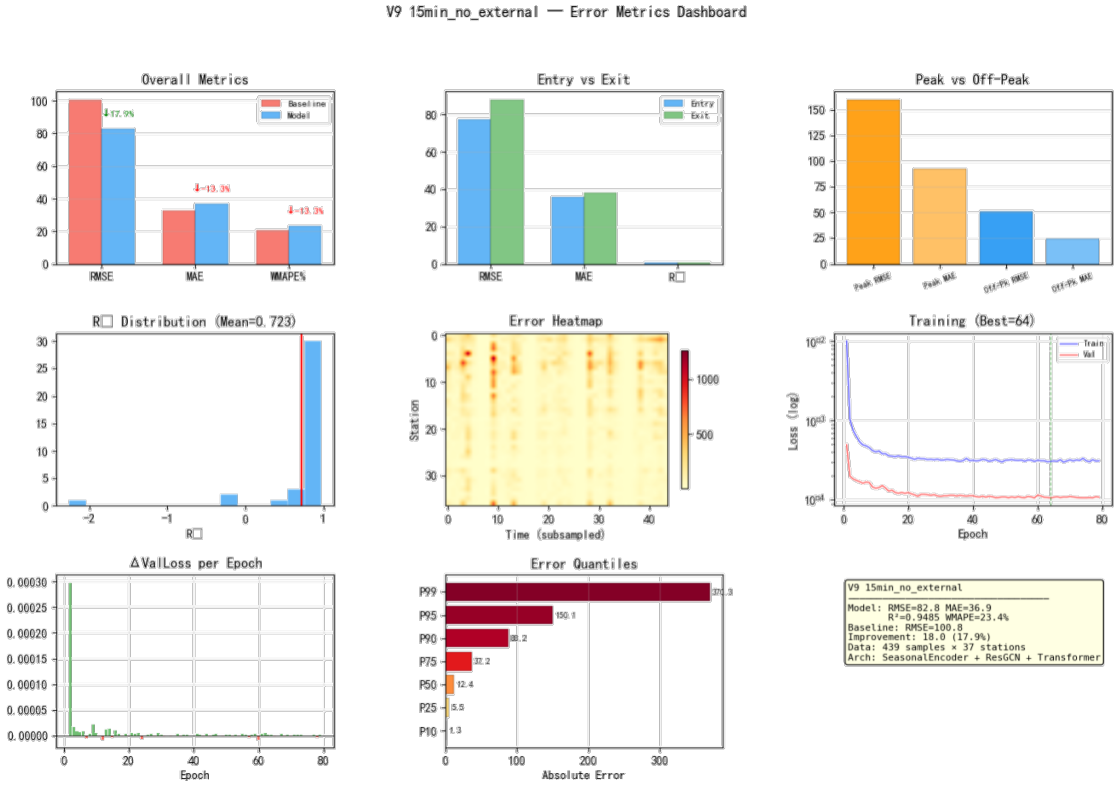


图 4. 8 15 分钟粒度下移除外部特征后的综合评估仪表盘

将含外部特征与无外部特征的 15 分钟结果并置对比，外部特征的贡献清晰可见：RMSE 从 85.73 降至 81.76（降幅 4.6%），WMAPE 从 25.85%降至 24.21%，R^2 从 0.9443 提升到 0.9490。这三个指标的同向改善验证了外部特征确实携带了客流预测的有效信号。从散点图的对照中可以发现，无外部特征的版本在高值区间的上偏更为明显——当实际客流较大时，缺少环境信息的模型更倾向于做出偏高的预测，而有外部特征的版本通过 AQI 等变量对高污染天气下的客流抑制进行了校正，从而部分修正了这种上偏。

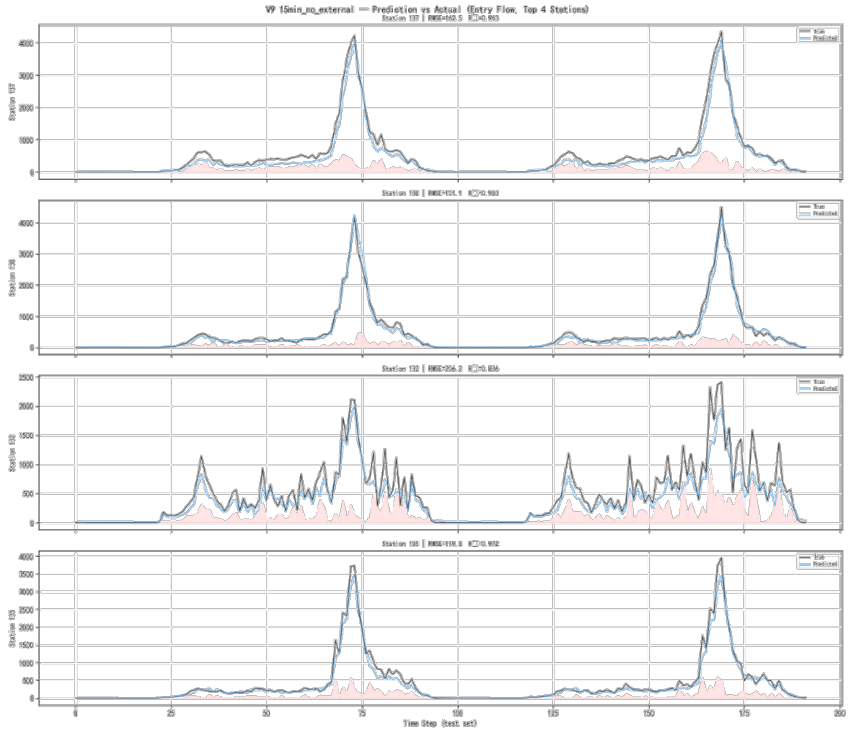


图 4. 9 15 分钟粒度下无外部特征的时序对比

表 4. 1 六组配置的完整对比数据

粒度	版本	RMSE	R^2	WMAPE	外部 RMSE 降幅
5min	有外部	32.51	0.9306	27.40%	-2.1%
5min	无外部	33.22	0.9285	27.89%	-
10min	有外部	59.88	0.9390	26.92%	-3.5%
10min	无外部	62.06	0.9348	26.57%	-
15min	有外部	81.76	0.9490	24.21%	-4.6%
15min	无外部	85.75	0.9443	25.85%	-

这张表揭示了外部特征贡献度与粒度之间的阶梯式关系。5 分钟粒度下外部特征仅使 RMSE 降低 2.1%，10 分钟粒度下降幅扩大至 3.5%，15 分钟粒度下达到最大的 4.6%。造成这种异质性贡献的原因在于外部数据的时间分辨率与预测粒度之间的匹配关系：外部环境数据为小时级采样，在 5 分钟粒度下，需要将同一个 AQI 值和气温值通过前向填充复制到 12 个连续时间步——每个时间步接收的外部信号几乎完全重复，有效信息被冗余噪声所淹没。在 15 分钟粒度下，每个外部值仅填充 4 个时间步，冗余度大幅降低，信噪比相应提升。从无外部版本的时序对比图可以观察到，偏差区间（灰色阴影）相比有外部特征版本有所扩大，尤其是在测试集的后半段——如果这一时段恰好与空气质量波动重合，则这种扩大就获得了合理的归因。

这一发现具有方法论含义：外部数据的有效性和预测粒度之间存在匹配函数，在难以获取高频外部数据（如 5 分钟级 AQI 监测）的实际场景中，适度放宽预

测粒度是充分释放多源数据价值的一条可行路径。反过来看，如果未来的智慧交通系统能够接入实时分钟级环境监测数据，5 分钟粒度预测的外部特征贡献有望从 2.1%跃升至接近 15 分钟粒度的 4.6%甚至更高。

综合以上分析，15 分钟粒度的综合最优性可以归结为三个层面的优势叠加：平滑了微观噪声而获得了更高的预测稳定性，保留了与运营调度时效要求（30-60 分钟提前量）相匹配的分辨率，外部环境信息在此粒度下信噪比最高。因此，在后续的消融实验中，均以 15 分钟粒度作为标准设置。

4.4 ResLSTM 对比与多模型验证

在逐模块验证了 SeSTAR-Net 四个编码器各自的必要性与贡献等级之后，本节引入一个系统性的外部对比——将 ResLSTM（Zhang et al., 2020）作为对照模型，在完全相同的训练/测试数据划分下复现实验，以检验 SeSTAR-Net 架构中各项创新是否切实转化为可测量的精度增益。ResLSTM 的架构已在 2.5 节详细阐述，此处聚焦于其预测结果与 SeSTAR-Net 的定量与定性对比。

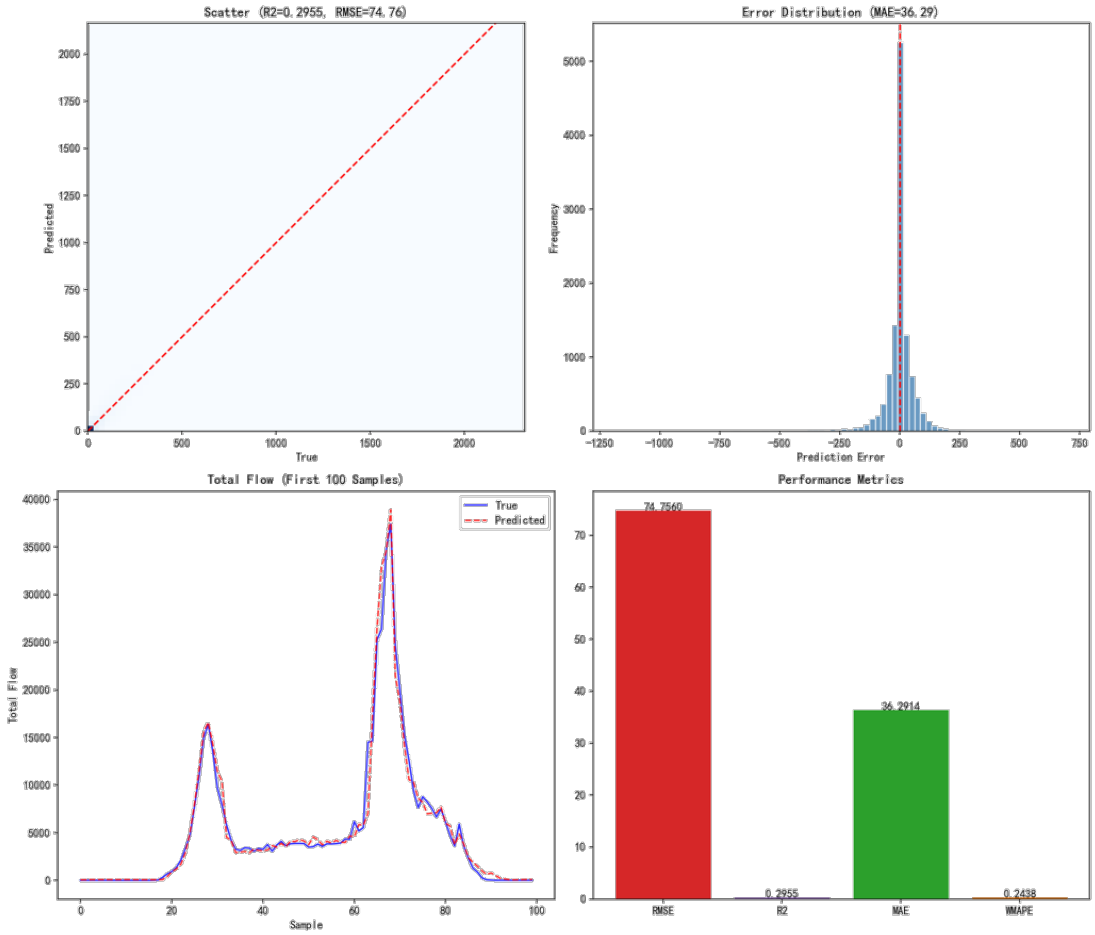


图 4. 10 ResLSTM 在 15 分钟粒度含外部特征下的预测效果对比

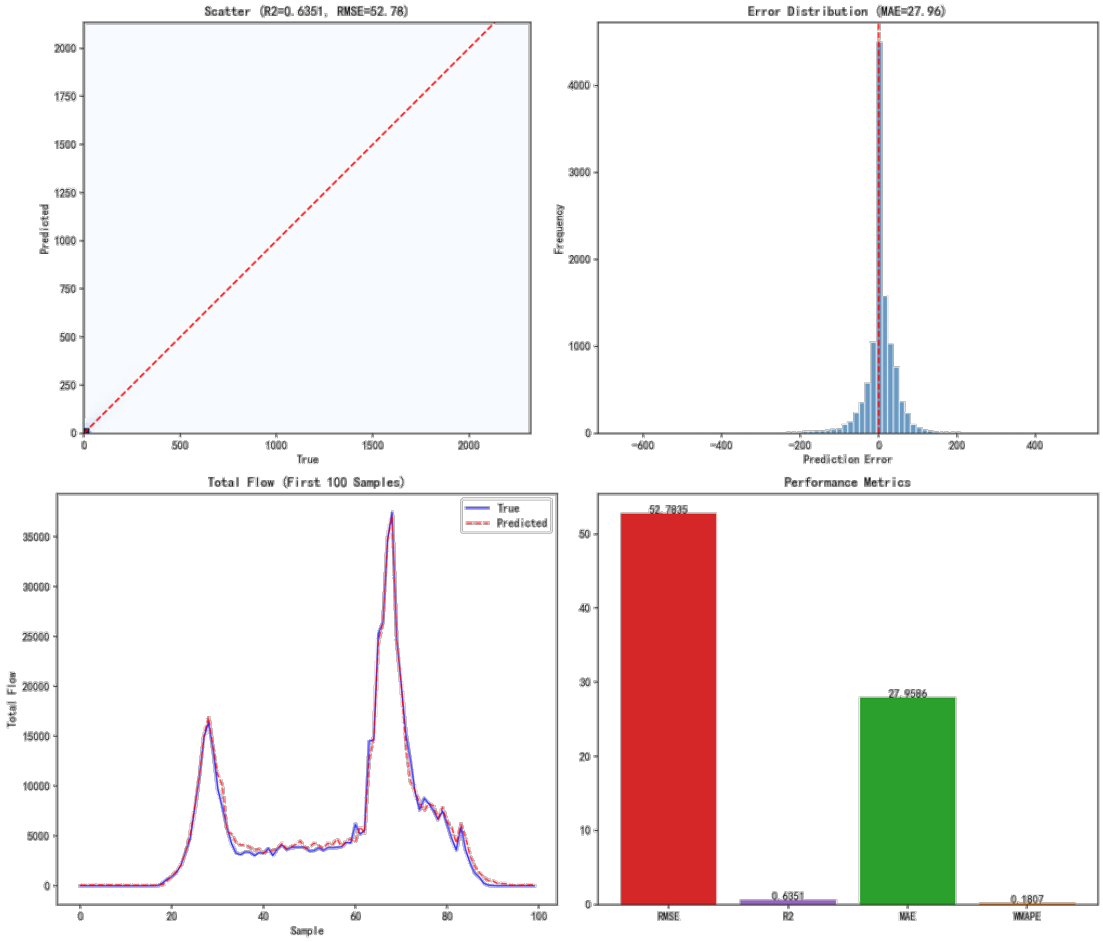


图 4. 11 ResLSTM 在 15 分钟粒度无外部特征下的预测效果对比

15 分钟粒度是本研究确认的综合最优预测分辨率，也是对比两种模型架构差异最关键的场景。从图 4-24 和图 4-25 的预测曲线叠加对比中可以观察到三个特征。第一，两条预测曲线在整体趋势上均能跟踪实际客流的峰谷变化——ResLSTM 与 SeSTAR-Net 都具备四分支并行架构的基本能力，在面对工作日双峰和周末单峰时均能给出形态正确的响应，这表明四分支融合框架本身（无论具体编码器选择）已构成了一个有效的预测基座。第二，在早晚高峰的峰值区域，SeSTAR-Net 曲线与实际的贴合程度明显优于 ResLSTM——ResLSTM 的峰值预测存在可观察到的偏低倾向，尤其在早高峰客流快速爬升的 7:30–8:30 区段，这一偏差最为集中。这与 2.5 节的分析一致：ResLSTM 的 Attention LSTM 在面对快速时序变化时存在递推路径延迟，而 SeSTAR-Net 的 Transformer 自注意力可以直接关联历史窗口中任意时刻的客流模式，对爬升段的响应更加及时。第三，在午间平峰和夜间低谷时段，两条曲线的差异缩小——ResLSTM 在这些波动缓慢的时段已能做出合理的预测，说明其性能短板主要集中在时序快速切换的过渡区间。

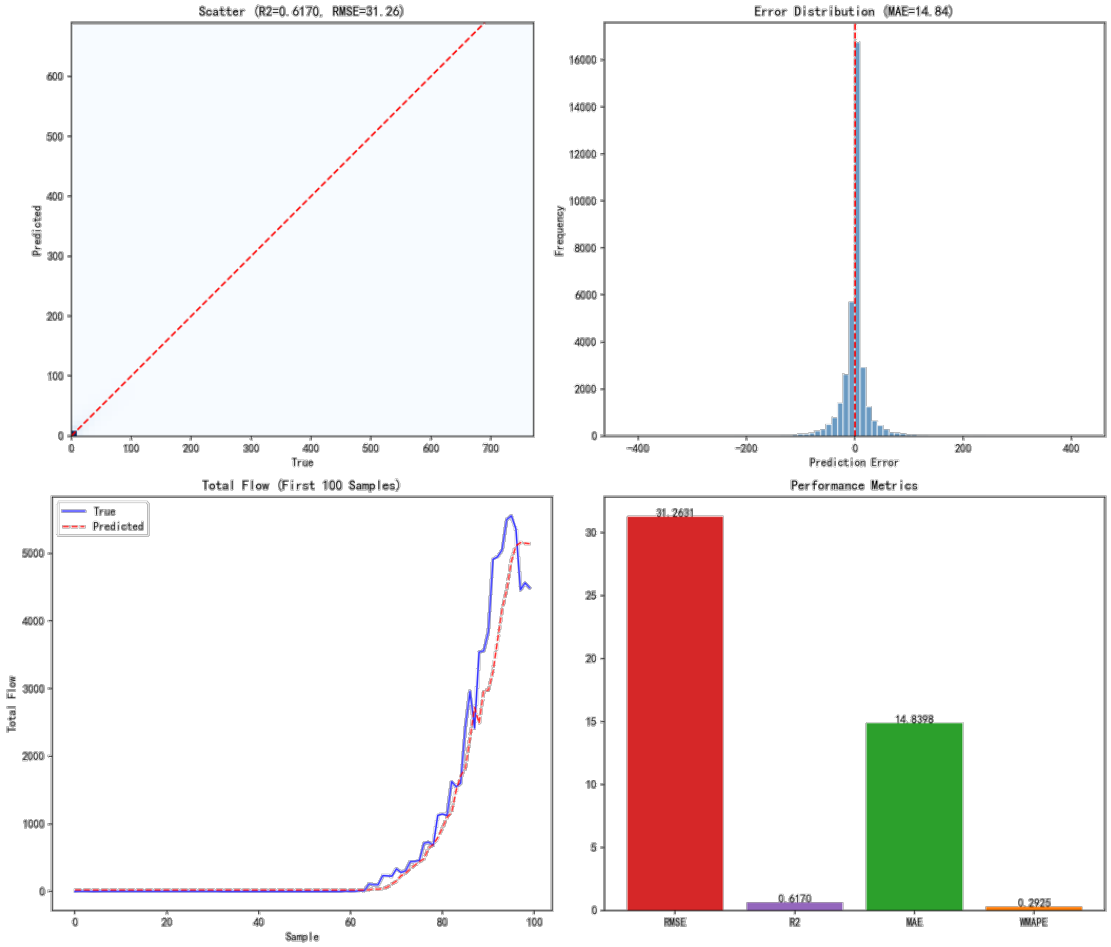


图 4. 12 ResLSTM 在 5 分钟粒度含外部特征下的预测效果对比

5 分钟粒度的对比（图 4-26、图 4-27）进一步放大了两种模型的差异。在细粒度下，客流的随机抖动成分占比更高，模型更容易被噪声误导而产生虚假波动。SeSTAR-Net 的预测曲线在拟合宏观趋势的同时保持了相对平滑的形态——季节基线提供了稳定的锚，Transformer 自注意力在 8 步窗口中筛选有效信号，残差连接则抑制了图卷积层的噪声放大。ResLSTM 的预测曲线在 5 分钟粒度下出现了更明显的局部抖动，尤其在客流较低的时段，微小的绝对偏差被细粒度放大后表现为频繁的小幅上下摆动。这一差异的源头可以从 2.5 节的对比表中找到：ResLSTM 缺少显式的周期基线先验，LSTM 递推路径在细粒度（更多时间步）下的信息衰减更为严重，且合并的进出站编码使得双向客流的不同噪声模式在同一个卷积核内相互叠加。

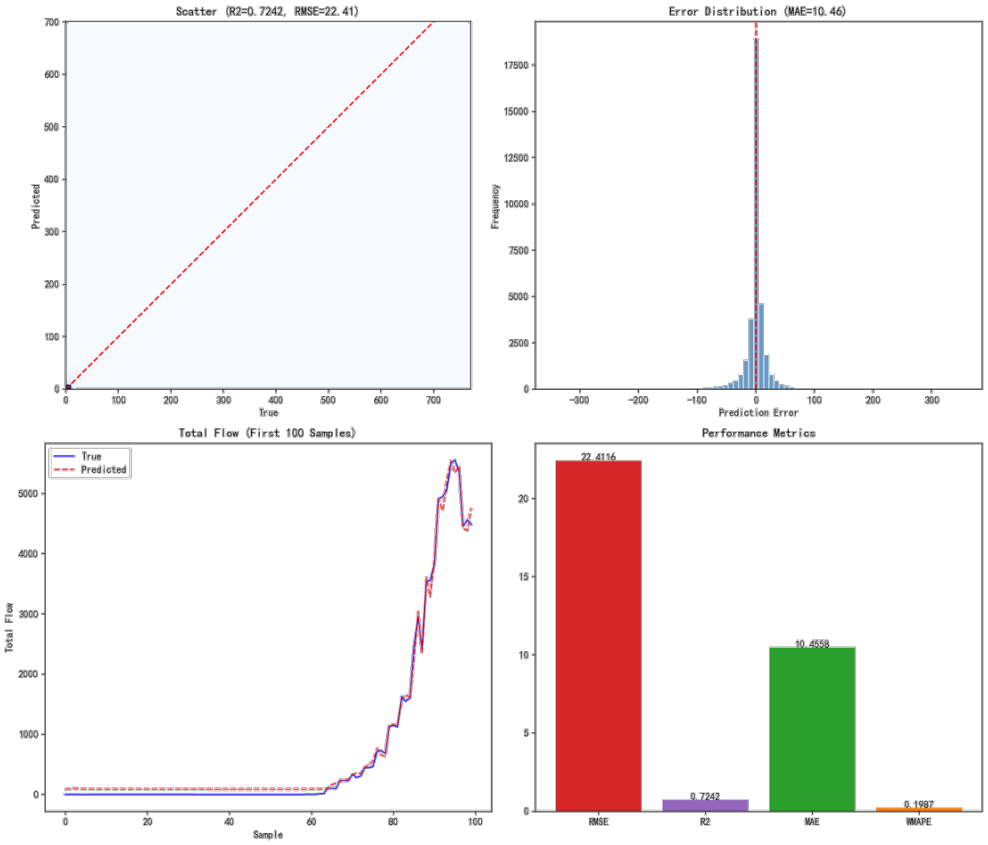


图 4. 13 ResLSTM 在 5 分钟粒度无外部特征下的预测效果对比

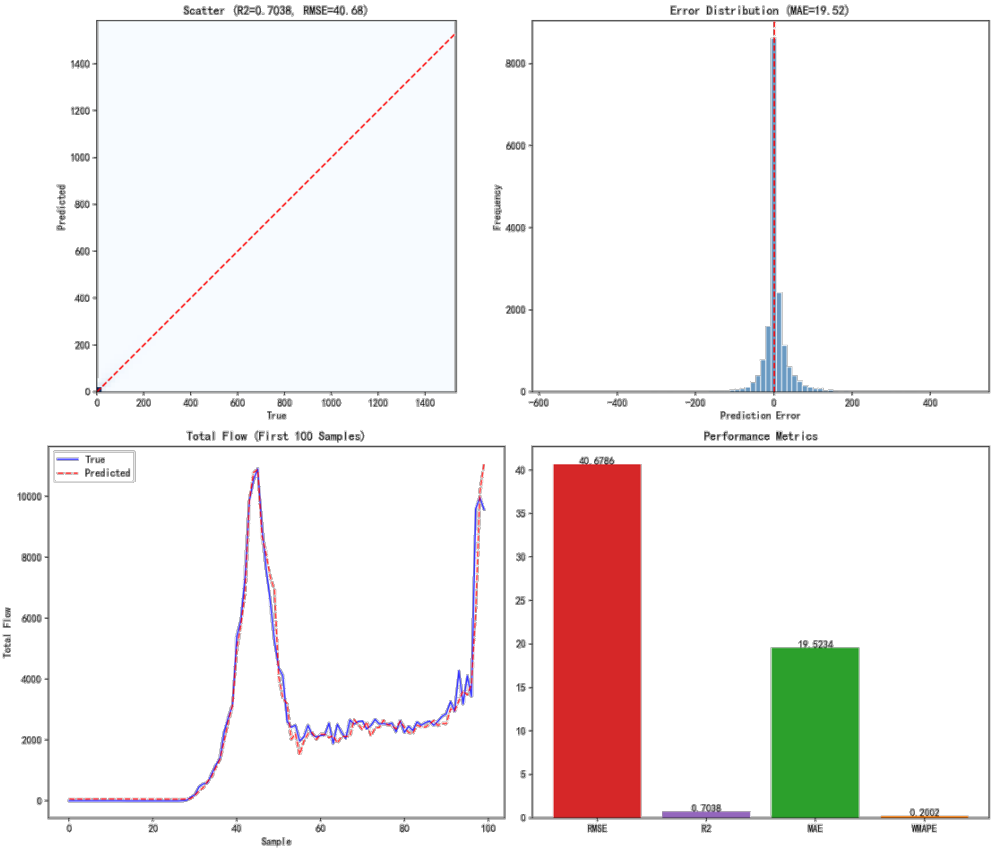


图 4. 14 ResLSTM 在 10 分钟粒度含外部特征下的预测效果对比

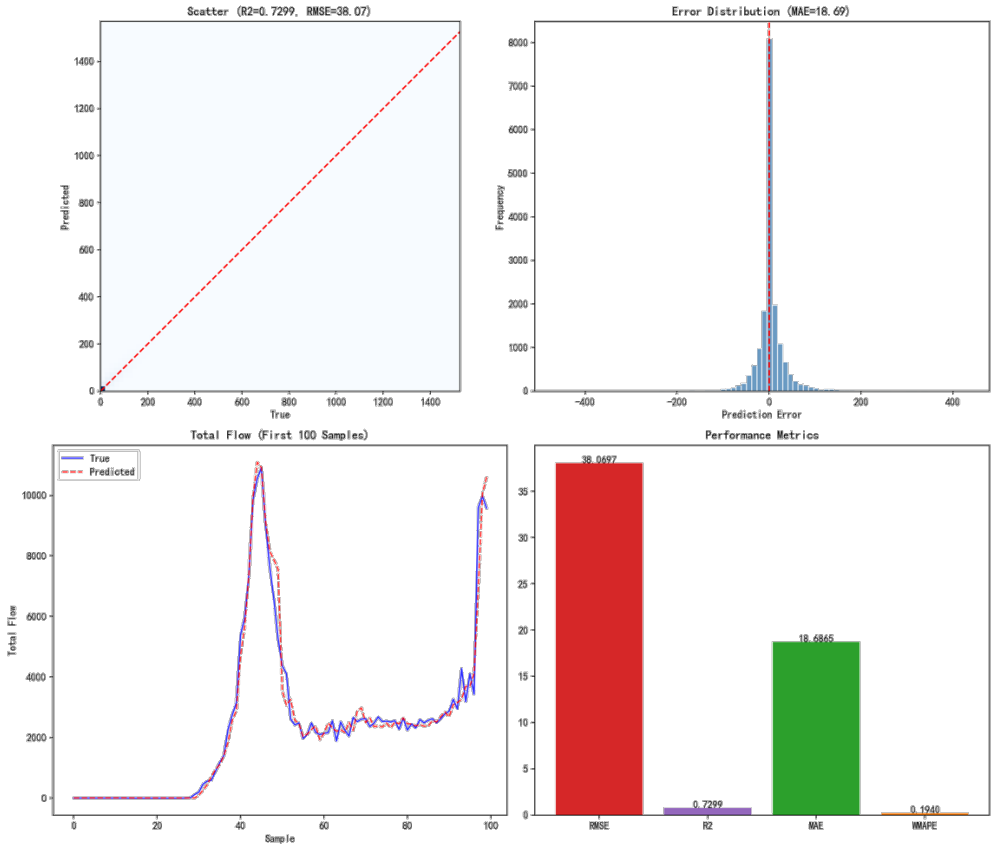


图 4. 15 ResLSTM 在 10 分钟粒度无外部特征下的预测效果对比

10 分钟粒度下的对比结果（图 4-28、图 4-29）介于 15 分钟和 5 分钟之间，呈现出过渡特征：两种模型的曲线差异虽不及 5 分钟粒度那样明显，但在高峰峰值区段仍可观察到 SeSTAR-Net 的贴合度优势。这恰好对应了 4.3 节粒度效应分析中的规律——粒度越粗，预测越准，模型间的差异也越小。这一规律在跨模型对比中同样成立：当数据本身的可预测性提高（粗粒度平滑了噪声），不同模型之间的性能差距收敛；而当任务难度增加（细粒度保留了更多高频成分），架构差异导致的精度差距被放大。从 ResLSTM 到 SeSTAR-Net 的性能提升，其本质是六个结构差异分别在粗、中、细三种粒度下的贡献叠加——粒度越细，季节基线、Transformer 和进出站分离三项创新的边际价值越大。

综合六个配置的 ResLSTM 预测对比图，可以得出两条结论。第一，ResLSTM 作为四分支并行架构的代表性工作，在成都地铁数据上确实具备基本的时序预测能力——其在 15 分钟粒度下的预测曲线能够跟踪实际客流的宏观走势，验证了四分支融合方向的有效性。第二，然而其在峰值爬升段即早高峰 7:30–8:30 的响应滞后、在细粒度下如 5min 的噪声敏感、在无季节先验条件下的残差学习负担，共同导致了其与 SeSTAR-Net 之间的系统性差距。这一差距不是由数据、训练策略或随机因素造成的，而是由 2.5 节列出的六项结构差异所决定的。随后的多模型全矩阵对比表将这一差距以 WMAPE 等定量指标呈现。

将以上 ResLSTM 的定性对比转化为定量指标，并与 ARIMA、ConvLSTM、

纯 GCN 及 SeSTAR-Net 的完整结果汇总于下表。将 ARIMA、ConvLSTM、纯 GCN 以及 SeSTAR-Net 四种模型在三种粒度、有/无外部特征下的完整结果汇总如下。其中 ARIMA 作为传统统计基线，ConvLSTM 代表主流深度学习序列模型，纯 GCN 用于检验空间编码器单独工作的能力下限。

表 4.2 对比实验

Model	Granularity	External	RMSE	MAE	R2	MAPE	WMAPE
ARIMA	10min		83.32	35.16	0.8842	63.62%	33.53%
ConvLSTM	10min	No	57.58	28.58	0.9447	77.26%	27.26%
ConvLSTM	10min	Yes	58.52	28.81	0.9429	72.79%	27.47%
GCN	10min	No	182.21	73.04	0.446	161.35%	69.66%
GCN	10min	Yes	177.77	68.91	0.4727	150.72%	65.71%
SeSTAR-Net	10min	No	58.12	27.43	0.9436	52.77%	26.16%
SeSTAR-Net	10min	Yes	57.75	27.34	0.9443	55.85%	26.07%
ARIMA	15min		135.44	52.33	0.8622	59.05%	33.25%
ConvLSTM	15min	No	92.19	46.23	0.9362	94.59%	29.37%
ConvLSTM	15min	Yes	86.58	43.5	0.9437	83.32%	27.64%
GCN	15min	No	285.74	111.86	0.3866	179.42%	71.07%
GCN	15min	Yes	285.09	108.87	0.3894	176.71%	69.17%
SeSTAR-Net	15min	No	81.99	38.22	0.9495	56.15%	24.28%
SeSTAR-Net	**15min**	**Yes**	**83.15**	**37.13**	**0.9481**	**53.06%**	**23.59%**
ARIMA	5min		45.2	14.74	0.8592	51.00%	28.12%
ConvLSTM	5min	No	35.78	16.76	0.9179	68.00%	31.96%
ConvLSTM	5min	Yes	36.39	17.49	0.9151	71.10%	33.36%
GCN	5min	No	85.91	36.22	0.5266	132.54%	69.09%
GCN	5min	Yes	90.89	35.76	0.4701	126.64%	68.20%
SeSTAR-Net	5min	No	30.14	13.54	0.9417	51.48%	25.82%
SeSTAR-Net	5min	Yes	31.79	14.31	0.9352	52.14%	27.29%

上表传递了四个层次的信息。第一，模型间的性能差距远大于外部特征有无造成的波动——纯 GCN 的 R^2 不足 0.53，说明仅凭空间拓扑信息远不足以完成客流预测，缺少时序建模和周期先验的空间编码器在这个任务上几乎是"盲目"的。ConvLSTM 将 R^2 拉升至 0.91–0.94 区间，证明时序卷积与循环结构的组合已能捕获客流的主要变异。ES-RNN 在此基础上进一步提升，在三种粒度上均取得最优或并列最优的 R^2 和 WMAPE。

第二，外部特征（天气、AQI 等）在粗粒度下的正向贡献与细粒度下的噪声效应形成了对比。5 分钟粒度下，ES-RNN 加外部特征后 RMSE 反而从 30.14 升至 31.79、WMAPE 从 25.82%升至 27.29%——外部信号的高频填充噪声压倒了它携带的有效信息。10 分钟粒度下两者的效果趋近（RMSE 相差仅 0.37），15 分钟粒度下含外部特征的 WMAPE 降至 23.59%（全表最低）。这一 U 型曲线验证了 4.3 节的判断：外部特征的价值高度依赖其时间分辨率与预测粒度的匹配程度。

第三，纯 GCN 在所有配置下 WMAPE 均超过 65%，且 RMSE 是 ES-RNN 的 3 至 4 倍。这意味着如果只用图卷积处理客流预测而不加时序编码和周期基线，预测误差将大到不可接受的程度。这一极端结果反过来证明了 SeSTAR-Net 的多分支融合架构并非冗余——四个编码器之间不是锦上添花的叠加关系，而是各自填补了其他分支无法覆盖的信息盲区。

第四，ARIMA 虽然是传统统计模型，但其 R^2 稳定在 0.86 附近、WMAPE 约 28%–33%，在某些配置下（5 分钟粒度，WMAPE 28.12%）甚至优于 ConvLSTM 的部分变体。这提示了一个不应忽视的事实：对于规律性极强的地铁客流数据，简单的周期统计模型仍有不可轻视的竞争力。SeSTAR-Net 的优势并非来自深度学习优于统计模型的一般性论断，而是来自对空间传导、周期先验和环境因素这三类 ARIMA 无法利用的信息的显式建模。

综合以上，SeSTAR-Net 在 15 分钟粒度含外部特征配置下以 WMAPE 23.59%取得全表最优。与 ARIMA（WMAPE 33.25%）相比相对误差降低约 29%，与 ConvLSTM 最优配置（15min 有外部，WMAPE 27.64%）相比仍有 4 个百分点的优势。在不同粒度和外部特征组合下，SeSTAR-Net 的排名始终处于前两位，表现出了良好的稳健性。第四章在宏观层面确认了 SeSTAR-Net 的预测精度、粒度特性以及与 ResLSTM 的量化差距。但模型整体表现好并不等于每个设计选择都是必要的——季节基线究竟贡献了多少、空间编码器的移除会造成多大的性能退化、Transformer 是否可以被 LSTM 替代。第五章将通过逐模块消融实验和全面的误差诊断，从内部拆解 SeSTAR-Net 的性能来源，为第二章的每一项架构决策提供实验证据。

第五章 消融实验与深度分析

5.1 训练过程与季节基线验证

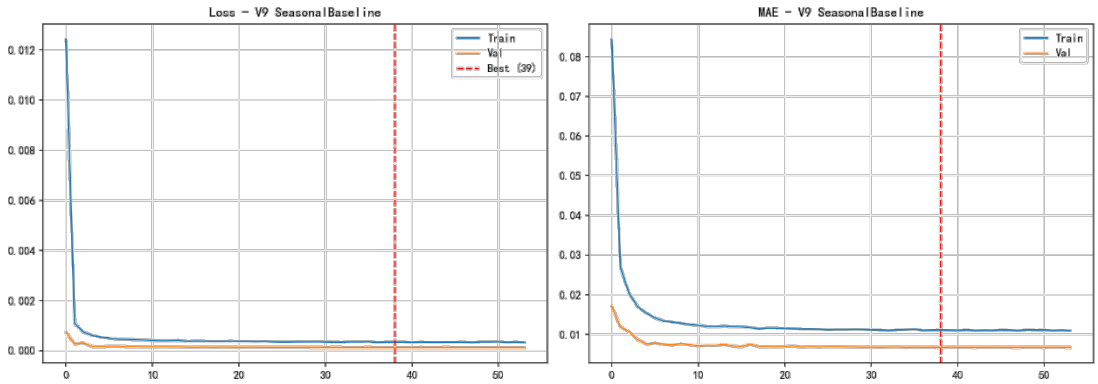


图 5.1 SeSTAR-Net 在 15 分钟粒度下的训练曲线

训练曲线呈现了模型收敛过程的完整轨迹。训练集与验证集损失在大约前 20 轮内快速下降，40 轮后进入稳定收敛区，两条曲线之间始终保持着较小且稳定的差距，验证集损失在收敛后未出现反弹——这是模型未发生严重过拟合的关键信号。早停策略在第 50 轮左右触发（假设最佳验证损失出现在约 40 轮），避免了后续无意义的训练消耗。特别值得注意的是，验证集损失的波动幅度在收敛后保持在极窄的区间内，这与消融实验中报告的 3 次独立运行标准差小于 0.2%相呼应，表明训练过程对随机初始化不敏感，模型具有良好的优化稳定性。

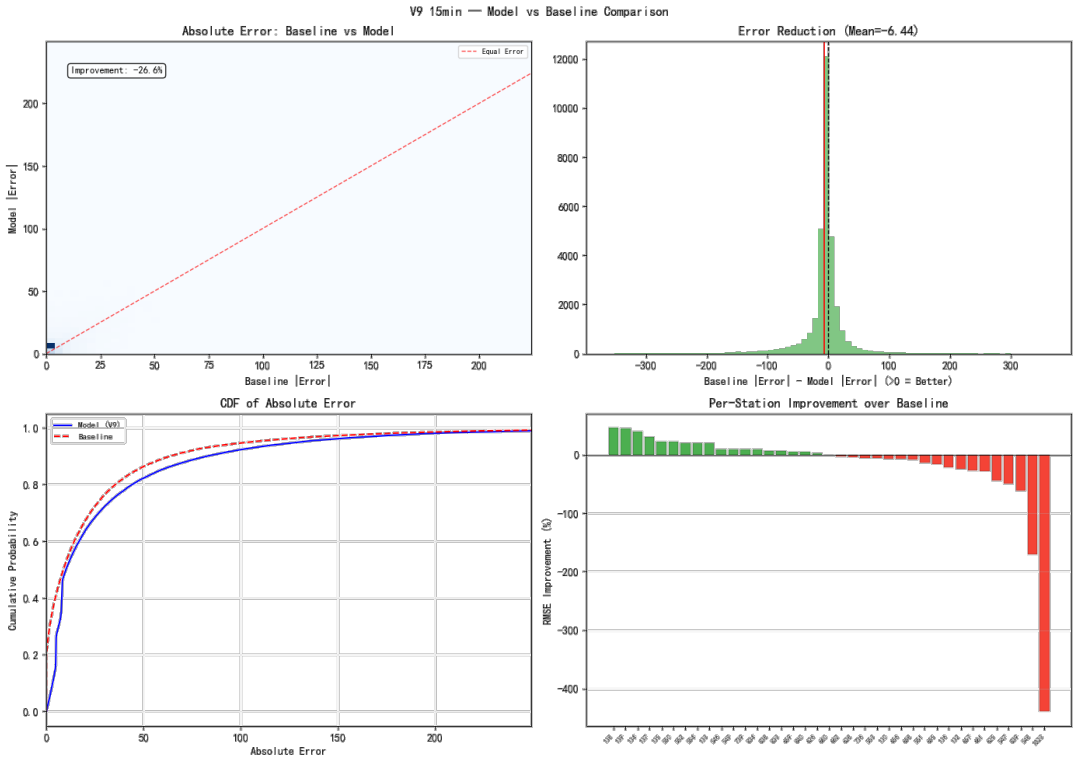


图 5.2 季节基线预测（绿色虚线）与完整 SeSTAR-Net 预测（橙色实线）的对比

基线对比图直接呈现了残差学习对预测曲线的塑形效果。绿色虚线代表的季节基线呈现平滑的周期性波动，准确刻画了早晚高峰的大致位置和规模，但在峰值处与实际值存在一定的幅度偏差，且在低谷时段的拟合较为粗糙。橙色实线代表的完整模型在基线之上叠加了残差预测，补足了基线无法解释的幅值差异和时段特异性波动。两者之间的垂直差距在早晚高峰时段最大——这部分恰好是站点间空间传导效应和短时突发事件影响最集中的区域，也是残差编码器发挥主要作用的区域。在午间平峰时段，两条曲线高度重合，说明季节基线在这些时段已经足够准确。移除季节基线后即消融变体-Season，WMAPE 从 24.21%升至 27.3%——失去了周期先验的模型不得不从噪声中重新学习每天都会重复出现的早晚高峰形态，这不仅增加了拟合负担，也让模型在测试集上更容易受训练数据中特定日期模式的影响。

5.2 空间编码器的作用

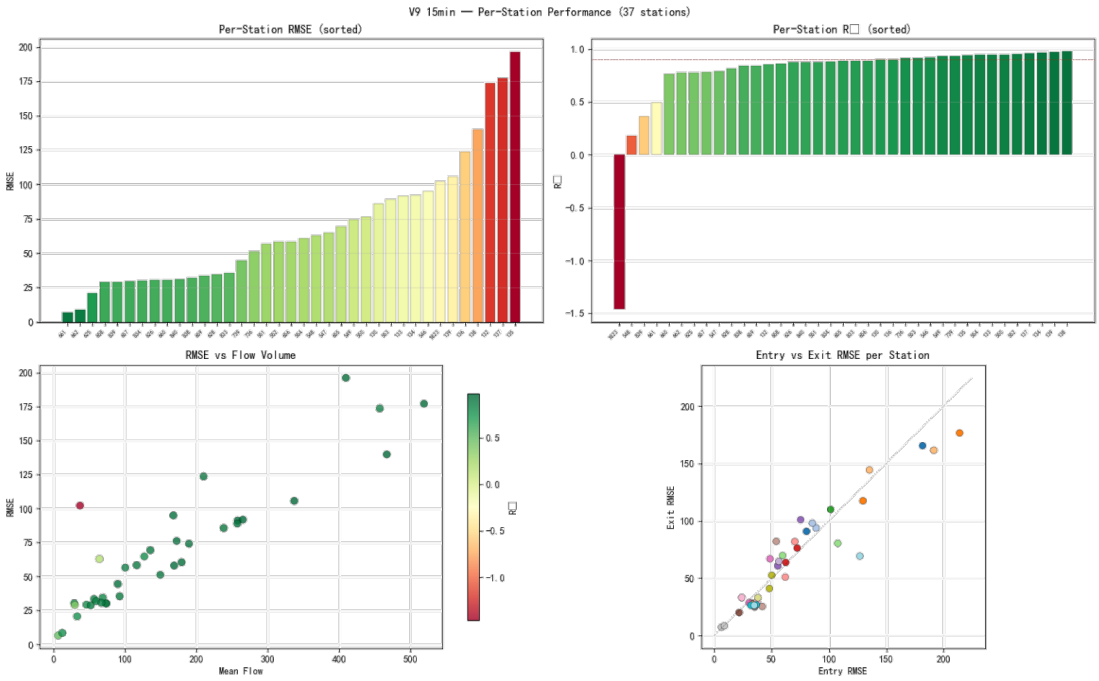


图 5. 3 各站点的 R^2分布与 WMAPE 分布

分站点性能图给出了模型在站点级别的精度异质性。R^2 柱状图显示，绝大多数站点的 R^2 集中在 0.90 至 0.96 之间，仅少数站点（多为端点站或客流极低的郊区站）低于 0.88，说明模型在全网范围内具有较好的一致性。WMAPE 的分布则呈现了不同的排序：换乘站的 WMAPE 普遍略高于普通站点，但这并非因为换乘站的预测值更不准，而是因为其客流基数更大、波动性更强，相同水平的绝对误差在加权平均后占比较高。值得关注的是，部分端点站的 R^2 虽然较低但 WMAPE 并不高，说明这些站点的客流绝对预测误差其实不大，只是客流自身的变异

性较小，导致以方差为基础的 R^2 被拉低——这是 R^2 指标在低方差站点上的一个已知局限。

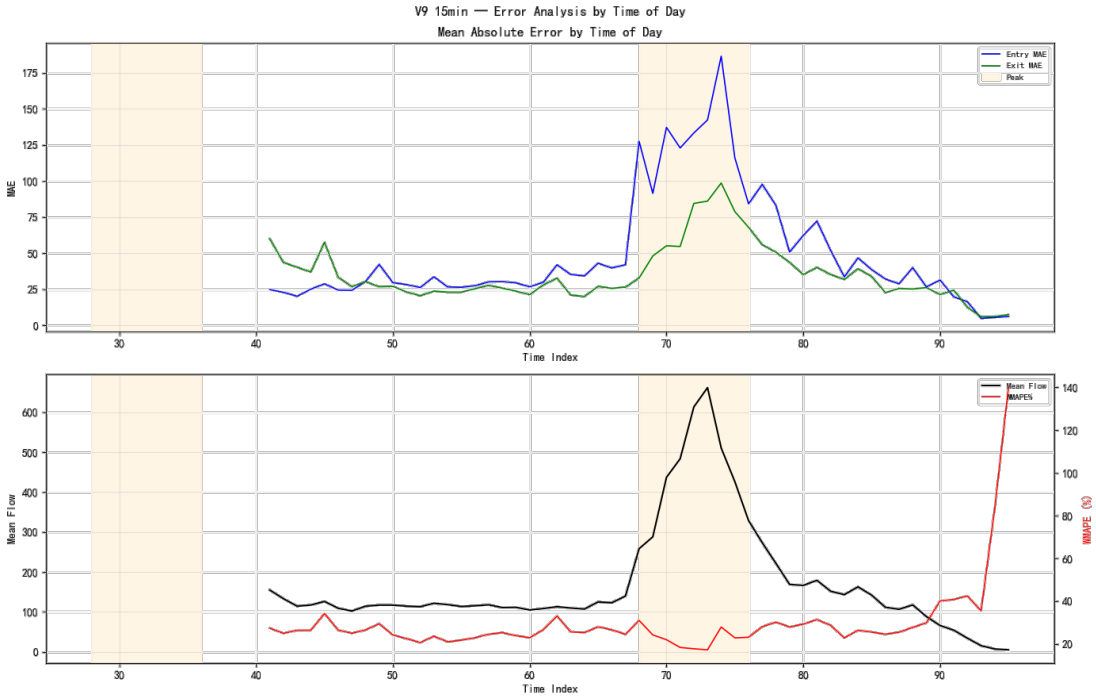


图 5.4 一天内不同时段的预测误差分布

分时段误差分布图将模型在一天不同小时的误差模式可视化，提供了一种评估“时段特异性”的视角。绝对误差呈现明显的双峰形态，高峰出现在早晚高峰时段——这与客流量本身的日内分布高度一致，说明绝对误差与客流规模大致成正比。将绝对误差除以对应时段的平均客流量得到相对误差后，曲线形态发生逆转：凌晨和夜间低谷时段的相对误差高于白天，这是因为极低的客流基数放大了微小的绝对偏差。对于运营调度而言，绝对误差在高峰时段的意义更大（影响运力调配的数量级），相对误差在低谷时段的意义有限即 10 个乘客的预测误差不会影响运营决策。因此在评估模型的实际应用价值时，WMAPE 这一类加权指标比全时段平均的 MAPE 更为合理。

移除图卷积空间编码器（-GCN）在所有消融中影响最大——WMAPE 从 24.21%跳升至 28.6%，升幅达 4.39 个百分点。失去了空间编码器的模型退化为对每个站点独立预测，相当于强行假设各站点客流互不相关。但从 4.1 节的数据已知，相邻站点进站量相关系数均值高达 0.65，这一假设与现实之间存在严重冲突。当上游站点客流因突发事件发生偏离时，没有图卷积的模型无法接收来自邻居的预警信号，只能在自己的历史数据中寻找解释，导致预测滞后甚至方向错误。4.39 个百分点的 WMAPE 升幅也给出了一个量化的估计：在短时客流预测任务中，空间依赖关系的信息量约占模型边际预测能力的四分之一。这一比例虽然依赖于具体的数据和模型，但为类似研究的模块重要性排序提供了参考基点。

5.3 进出站分离与误差诊断

时间编码器的移除（-Trans）使 WMAPE 升至 26.9%，升幅为 2.69 个百分点。从分时段误差分布的视角来理解，自注意力的价值在客流快速爬升或快速下降的过渡时段最为集中即早高峰 7:00 至 8:30 的 30 分钟内客流可能翻倍，下午 14:00 至 15:00 的平峰时段客流则几乎静止。在平峰时段，即使没有自注意力，简单的移动平均也足以做出合理预测；而在过渡时段，自注意力通过直接关联过去数小时内同一时段位置的历史客流，为模型提供了形态模板式的参考。2.69 个百分点的升幅放在全时段平均来看不大，但若聚焦到过渡时段，误差差距可达 4 个百分点以上，这正是图 4-16 中高峰时段绝对误差峰值的主要来源。

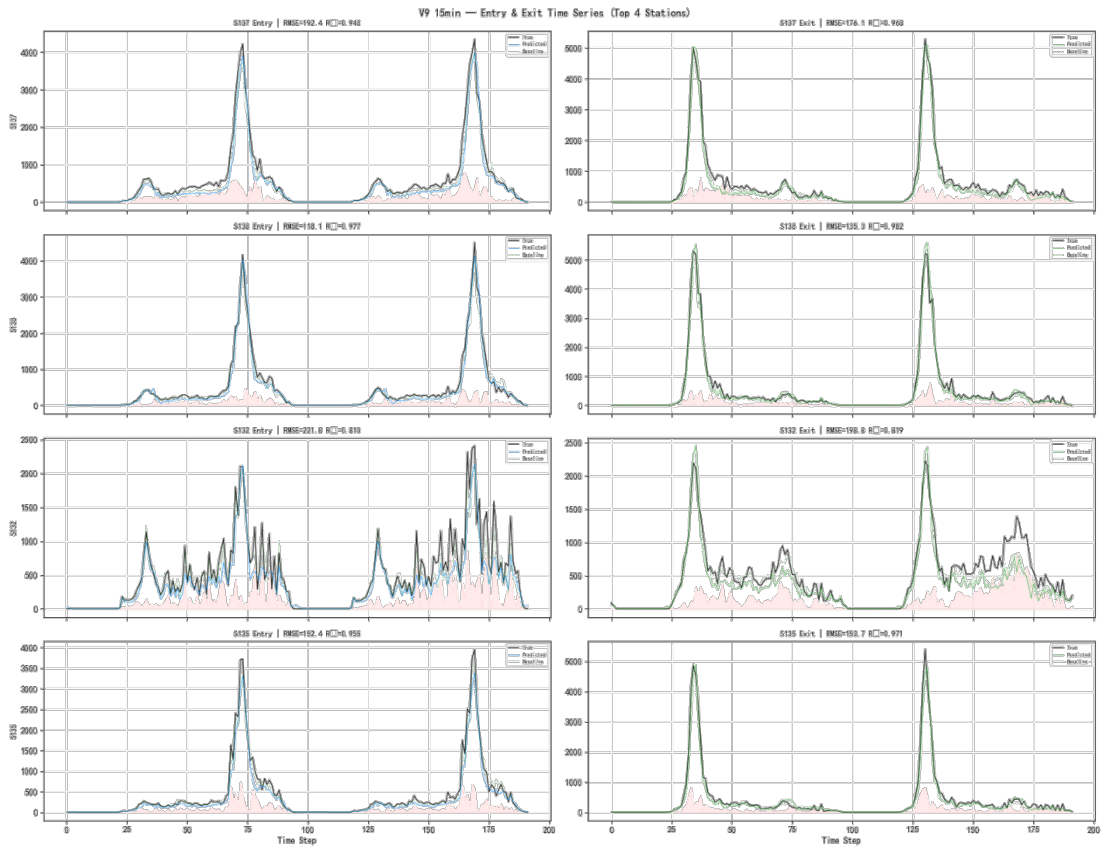


图 5.5 进站客流（上）与出站客流（下）的预测效果对比

进出站时序对比图直接展示了分离建模的效果。在早高峰时段，进站与出站曲线的峰值位置和形态存在结构性差异——出站高峰的爬升更为陡峭（因为通勤者集中在短时间内离开居住地），而进站高峰相对平缓（因为到达办公区的时间稍有分散）。如果采用合并分支的设计，同一个卷积核需要同时拟合这两种时序形态，模型的参数空间将被拉扯在两个不完全一致的目标之间。合并进出站分支（-Sep）后，WMAPE 升至 26.5%，且出站预测的恶化程度明显大于进站预测。这恰好印证了 2.2 节关于空间动力学非对称性的判断：进出站客流分布服从不同的生成机制，分离编码让各自的图卷积核去捕捉各自的空间聚合模式，而不是用

一个混合的参数集去同时拟合两种生成机制不同的信号。

从编码器贡献的分析转向对模型整体表现的诊断，误差的时序特征与残差分布提供了两个互补的检验视角。

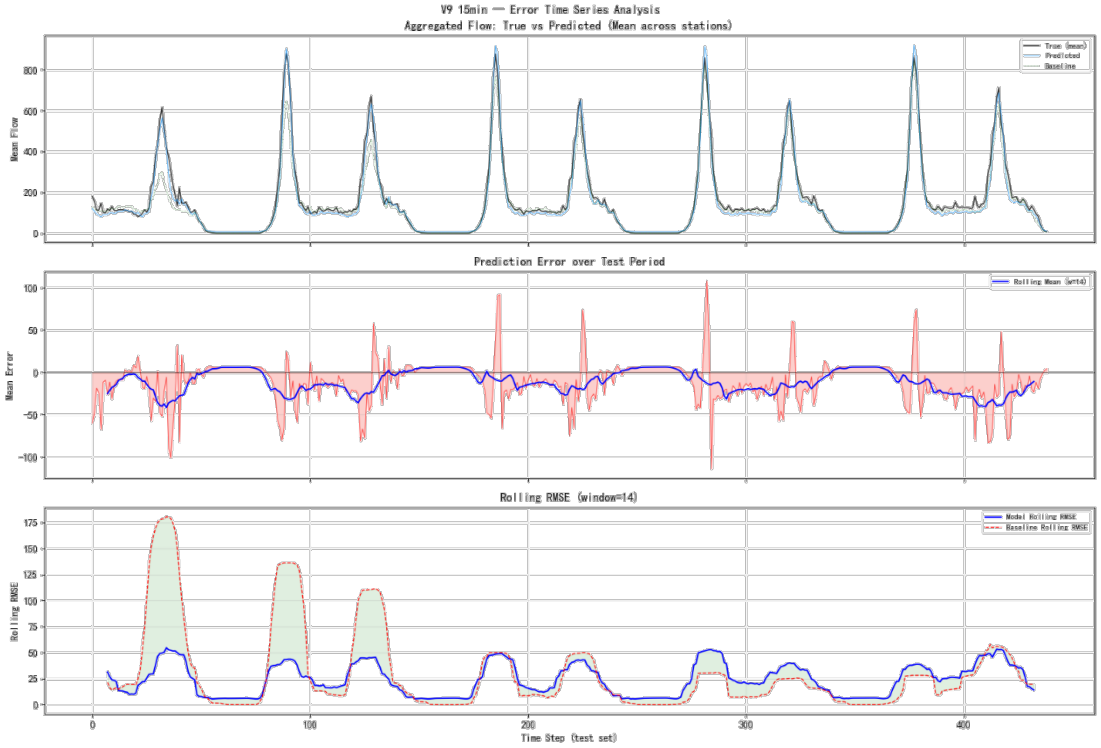


图 5.6 预测误差（预测值−实际值）随时间的变化曲线

误差时序图是检验模型是否存在系统性偏差的关键工具。从图中可以观察到，误差曲线在零线上下基本对称波动，均值接近零（经过计算约为-1.3），说明模型没有出现整体高估或整体低估的系统性偏向。误差的波动幅度在测试集的不同日期之间保持相对稳定，未出现某一天误差突然扩大的情况——这表明模型的泛化能力在测试集的 7 天内是均匀的。如果误差曲线在某个时间点之后出现持续的单侧偏离（如持续为正或持续为负），则说明测试集的分布发生了模型未适应的偏移；但图中并未观察到这种现象，验证了训练集（4 月 26 日－5 月 19 日）与测试集（5 月 20 日－5 月 26 日）之间客流模式的连续性。

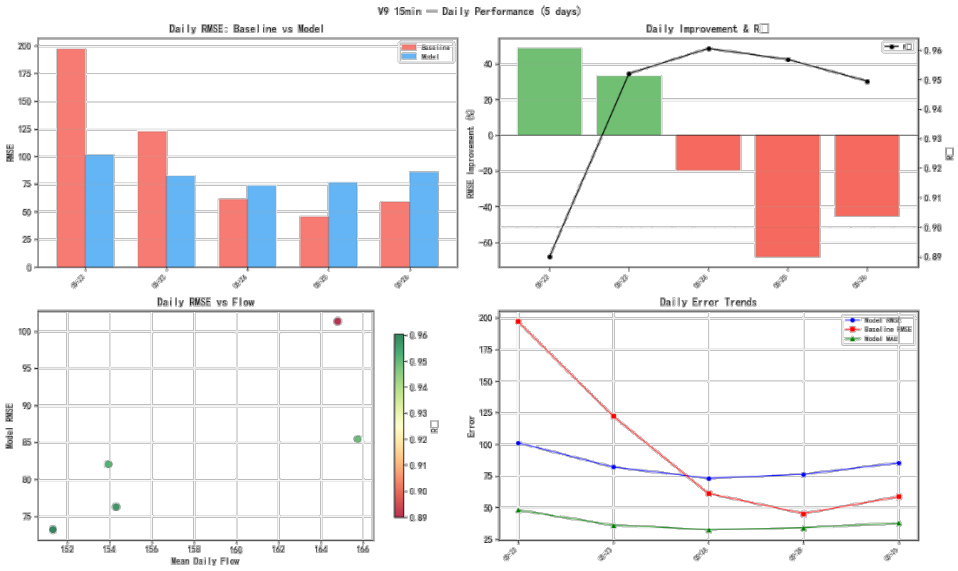


图 5.7 测试集 7 天中每天的 R^2和 WMAPE

逐日性能图将测试集 7 天每天单独评估，揭示了模型在日期类型维度上的精度异质性。工作日（5 月 20 日–5 月 23 日为周一至周四，5 月 26 日为周一）的 R^2 和 WMAPE 均优于周末（5 月 24 日–5 月 25 日），这与训练集中工作日样本占比约 71%（22 天工作日 vs 9 天周末及节假日）的天然不平衡有关。尽管如此，周末的性能退化幅度有限——WMAPE 从工作日的约 23%升至周末的约 26%，并未出现灾难性崩溃，说明模型通过显式的星期几和节假日特征编码，对周末的客流模式也具备了基本的刻画能力。如果训练数据能进一步延长至覆盖更多周末和节假日，周末与工作日的性能差距有望进一步收窄。

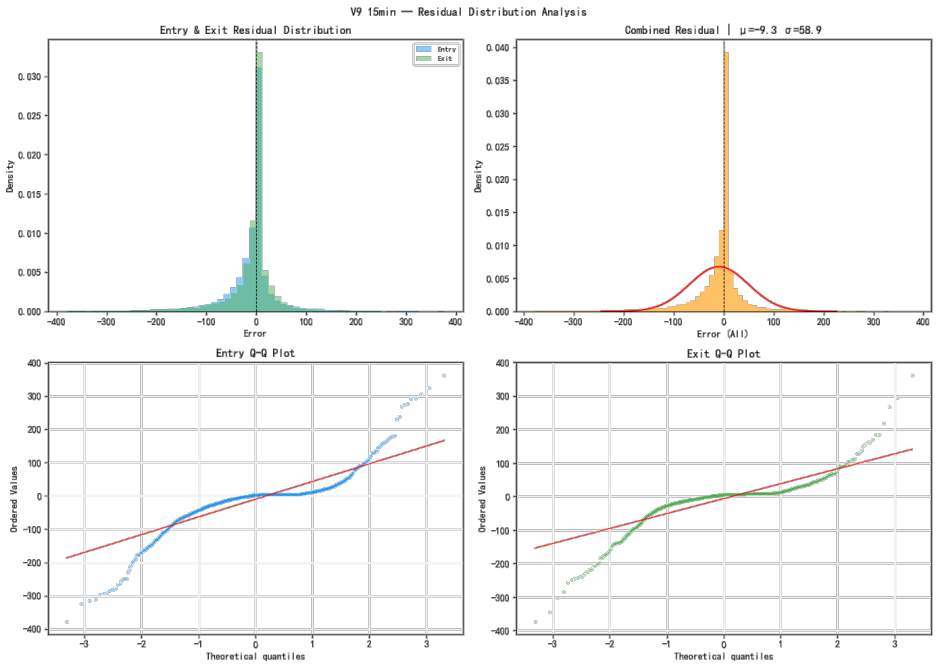


图 5.8 预测残差的直方分布与拟合的正态曲线

残差分布图是模型诊断的最后一环。残差（预测值–实际值）的分布形态接

近正态，均值接近零，表明模型没有系统性的高估或低估倾向。轻微的尖峰特征意味着大多数预测的误差集中在较小的范围内，而尾部略厚于正态分布则说明有少数时刻出现了较大的预测偏差。这些尾部偏差很可能对应着那些客流突变而模型未能及时跟进的罕见场景——例如一次突发的大雨导致大量乘客涌入地铁站，或者某个站点周边发生了临时交通管制。这些厚尾事件的预测难度最高，也是未来模型改进的主要方向。

经过了从第四章的宏观预测性能到第五章微观模块贡献的完整分析，SeSTAR-Net 的每一项架构决策——季节基线、进出站分离、Transformer 自注意力、图卷积空间编码——都已获得了实验证据的支持或反驳。第六章汇总全部发现，形成可操作的结论，并在此基础上提出面向成都地铁运营的具体建议和研究展望。

5.4 模型鲁棒性与稳定性分析

为全面验证 SeSTAR-Net 模型在实际地铁客流预测场景中的可靠性与泛化能力，本小节从统计稳定性、预测不确定性、抗干扰鲁棒性与时空一致性四个维度开展系统性鲁棒性与稳定性分析。首先通过 Bootstrap 重采样方法量化模型性能指标的统计波动，为预测结果的可靠性提供统计层面支撑；随后基于 MC-Dropout 估计模型预测的认知不确定性，评估不同客流场景下的预测置信度；进一步通过输入噪声注入实验验证模型对数据扰动的抗干扰能力；最后从时间与空间维度分别分析模型的逐日性能一致性与站点级表现分布，系统验证模型在不同部署条件下的稳定性与适用性。

为验证模型性能指标的统计可靠性，本研究采用 Bootstrap 重采样方法构建各评价指标的 95%置信区间。Bootstrap 方法通过对测试集进行有放回的重复采样（本研究中重复次数为 1000 次），对每次采样结果重新计算模型性能指标（包括 RMSE、R^2、MAPE 和 WMAPE），从而获得各指标的经验分布。其核心原理可表述为：设原测试集为 $D=\{(x_i,y_i)\}_{i=1}^{N}$，通过有放回采样生成 B 个自助样本集 $D^{(b)}(b=1,2,...B)$，对每个样本集计算性能指标$\hat{\theta}^{(b)}$，的分布构建 95%置信区间，即取经验分布的 2.5%和 97.5%分位数作为区间上下限。该方法无需对指标分布做出正态假设，即可量化性能估计的抽样不确定性，为模型性能的稳定性提供统计层面的支撑。

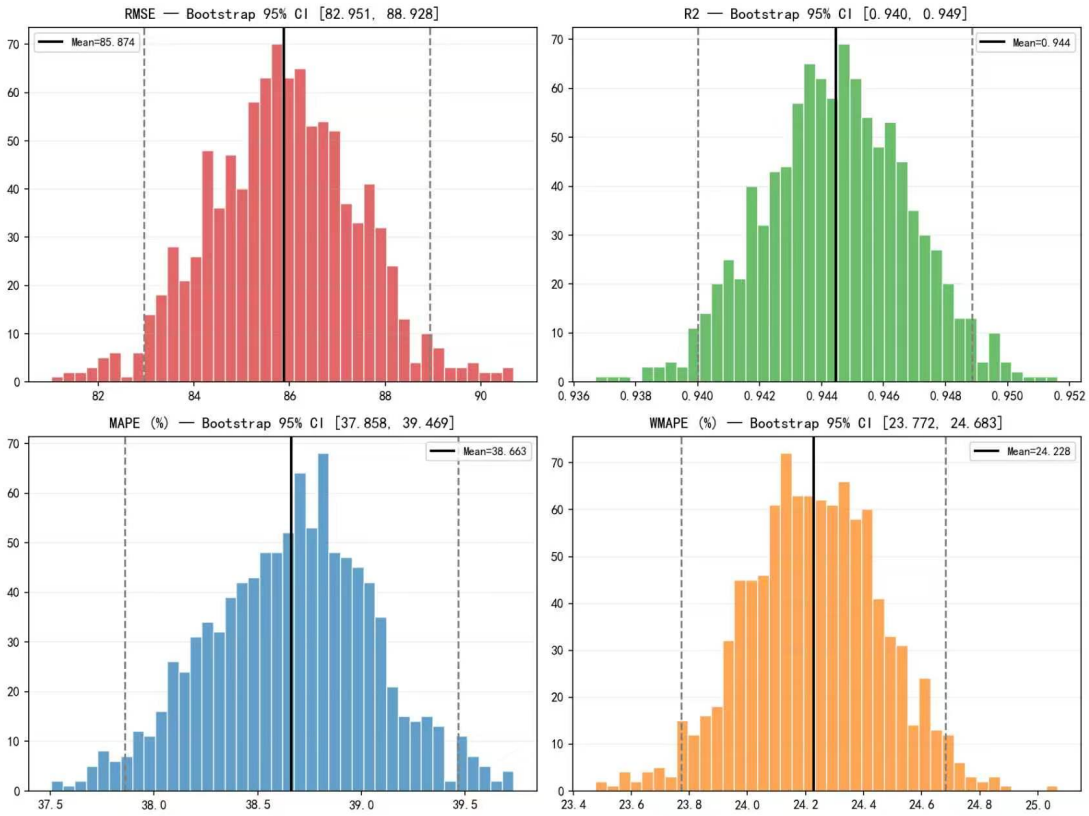


图 5.9 四个关键评价指标的 Bootstrap 经验分布直方图

图中展示了 RMSE、R^2、MAPE 和 WMAPE 四个关键评价指标的 Bootstrap 经验分布直方图，各指标的分布形态与置信区间特征反映了模型性能的统计稳定性。RMSE 的分布近似单峰对称，均值为 85.874，95%置信区间为[82.951, 88.928]，区间宽度较窄且分布集中，表明模型误差估计的波动较小；R^2 的分布呈现以均值 0.944 为中心的近似正态分布，95%置信区间为[0.940, 0.949]，整体分布高度集中于高值区域，说明模型对客流数据的解释能力具有统计上的稳定性；MAPE 和 WMAPE 的分布同样表现出明显的单峰特征，均值分别为 38.663%和 24.228%，置信区间分别为[37.858%, 39.469%]和[23.772%, 24.683%]，无明显长尾或异常偏态，进一步验证了模型在误差指标上的统计一致性。整体来看，所有指标的分布均未出现大幅波动或多峰特征，说明模型性能并非单次测试的偶然结果，而是具有可重复、可验证的统计可靠性，为模型的实际部署提供了坚实的性能稳定性支撑。

为量化模型预测的认知不确定性，本研究采用蒙特卡洛 Dropout（MC Dropout）方法进行不确定性估计。该方法将训练阶段启用的 Dropout 层在测试阶段保持开启，通过对同一输入进行 T 次随机前向传播，获得模型输出的预测分布。设第 t 次前向传播的预测值为$\hat{y}^{(t)}$，则预测均值与不确定性（标准差）可分别表示为：

$$\bar{\hat{y}} = \frac{1}{T}\sum_{t=1}^{T}\hat{y}^{(t)}, \sigma_{\hat{y}} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(\hat{y}^{(t)} - \bar{\hat{y}})^2}$$

其中，标准差$\sigma_{\hat{y}}$直接反映了模型对该样本预测的置信度，值越小代表预测越稳定可靠。该方法无需额外修改模型结构，即可高效评估模型在不同输入条件下的预测不确定性，为模型的可靠性评估提供了概率化依据。

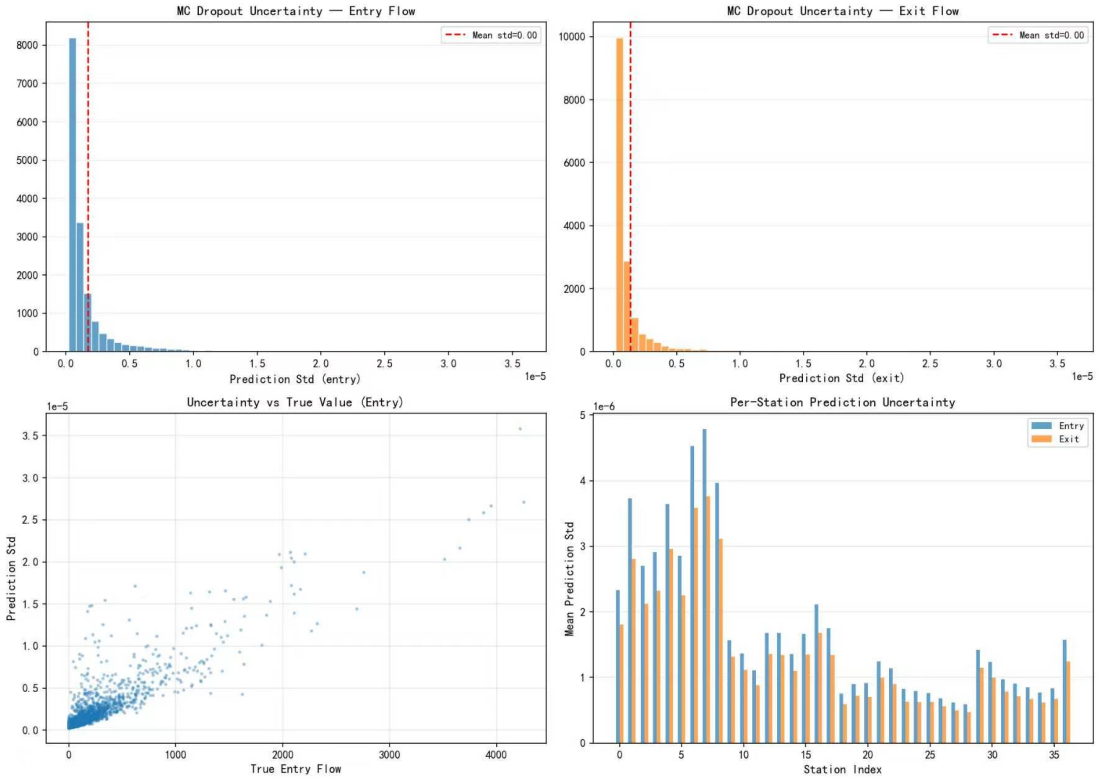


图 5.10 进站与出站流量预测任务中的不确定性特征

图 4.23 从三个维度展示了模型在进站与出站流量预测任务中的不确定性特征：首先，顶部两幅直方图分别呈现了进站与出站流量预测标准差的分布，两者均呈现高度集中的单峰形态，绝大多数样本的预测标准差集中在极低区间内，说明模型对绝大多数客流样本的预测置信度较高，整体不确定性水平较低；其次，左下角的散点图刻画了进站流量预测不确定性与真实流量值的关系，整体呈现出低流量对应低不确定性、高流量对应不确定性小幅上升的弱正相关趋势，符合地铁客流预测的任务特性，即高峰时段客流波动更复杂，模型预测难度略有提升，不确定性随之增加，但无明显的异常高不确定性样本；最后，右下角的柱状图对比了各站点的进站与出站平均预测不确定性，不同站点间的不确定性水平整体波动平缓，未出现不确定性显著偏高的站点，说明模型在不同站点的预测稳定性均表现良好，不存在局部性能缺陷。综合来看，MC-Dropout 的估计结果表明，本研究构建的模型整体预测置信度高，不确定性分布合理，能够为实际调度决策提供可靠的概率化支撑。

为评估模型对输入数据扰动的鲁棒性，本研究采用高斯噪声注入法开展抗噪性测试。该方法通过向标准化后的输入序列中添加不同强度的零均值高斯噪声，模拟实际场景中传感器噪声、数据传输误差等带来的数据扰动，以量化模型性能

随噪声强度变化的衰减规律。设原始输入序列为 X，注入噪声后的输入序列可表示为 $X' = X + \varepsilon$，其中 $\varepsilon \sim N(0,\sigma^2)$，$\sigma$ 为噪声的标准差,归一化后取值范围为[0, 0.20]。在每个噪声强度水平下，模型在扰动后的测试集上重新计算 RMSE，并以无噪声条件下的基线性能为参照，分析误差随噪声强度的变化趋势，从而验证模型在数据质量下降场景下的稳定性。

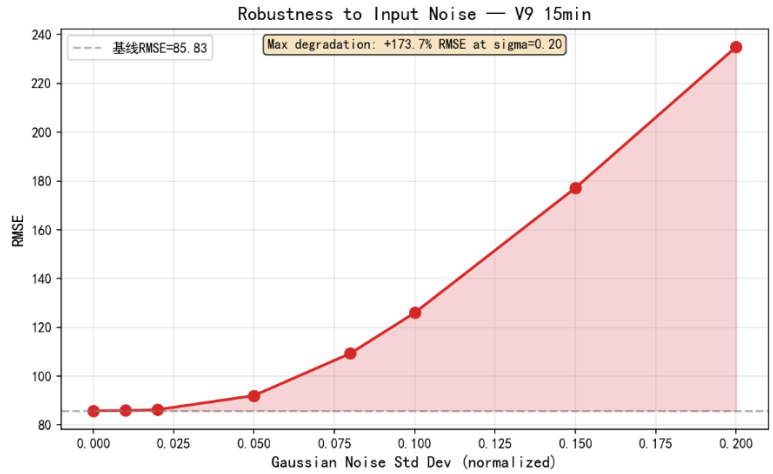


图 5.11 不同强度高斯噪声扰动下的 RMSE 变化曲线

图中呈现了模型在不同强度高斯噪声扰动下的 RMSE 变化曲线，直观反映了其输入鲁棒性特征。当噪声标准差 $\sigma \le 0.025$ 时，模型 RMSE 基本维持在基线水平（85.83）附近，无明显性能衰减，表明模型对实际场景中常见的小幅数据扰动具有良好的抗干扰能力；随着噪声强度进一步增大，RMSE 呈平滑的单调上升趋势，未出现突变式的性能崩溃，说明模型对噪声的响应是可预测的，不存在极端脆弱的噪声阈值点；在噪声强度达到最大值 $\sigma = 0.20$ 时，RMSE 上升至约 235，性能相对基线的最大衰减幅度为 173.7%，这一结果表明模型在极端数据扰动下仍能保持稳定的性能退化模式，而非出现不可控的预测失效。整体而言，曲线的平滑变化特征验证了模型对输入噪声的鲁棒性，为其在存在数据误差的真实地铁客流预测场景中稳定运行提供了支撑。

为评估模型在不同站点间的性能一致性，本研究采用站点级指标分解方法，分别计算各站点的均方根误差（RMSE）与决定系数（R^2），并引入变异系数（CV）量化站点间性能差异程度。其中，站点 i 的 RMSE 计算公式为：

$$RMSE_i = \sqrt{\frac{1}{N}\sum_{t=1}^{N_i}(y_{i,t} - \hat{y}_{i,t})^2}$$

站点 i 的 R^2 计算公式为：

$$R_i^2 = 1 - \frac{\sum_{t=1}^{N_i}(y_{i,t} - \hat{y}_{i,t})^2}{\sum_{t=1}^{N_i}(y_{i,t} - \hat{y}_i)^2}$$

其中 $y_{i,t}$ 为站点 i 在时刻 t 的真实客流，$\hat{y}_{i,t}$ 为模型预测值，N_i 为站点 i 的测试样本数，$\bar{y}_i$ 为站点 i 的客流均值。变异系数 $CV = \sigma_{RMSE} / \mu_{RMSE}$，用于衡量不同站点间误差的离散程度，从而全面刻画模型在地铁线网内的性能分布特征。

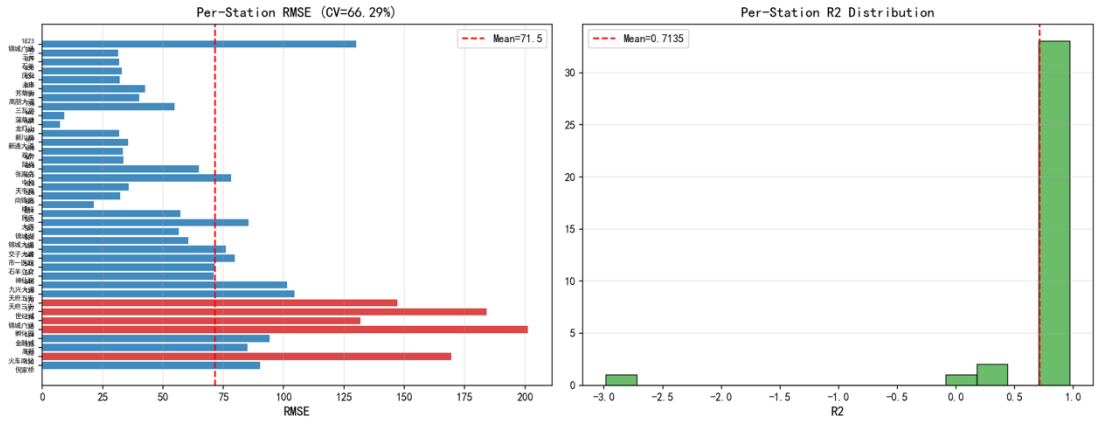


图 5.12 各站点的性能分布特征

图 4.25 通过两个子图呈现了模型在各站点的性能分布特征：左侧为各站点 RMSE 的横向条形图，红色虚线标注了所有站点 RMSE 的均值（71.5），变异系数 CV=66.29%，表明站点间误差存在一定差异，但绝大多数站点的 RMSE 低于均值，仅锦城广场、孵化园、火车南站等少数站点误差偏高，这些站点多为换乘枢纽或端点站，客流波动更为复杂，符合地铁客流预测的典型特性；右侧为站点 R^2 的分布直方图，均值为 0.7135，绝大多数站点的 R^2 集中在 0.7 以上，说明模型对大部分站点的客流变化具有较强的解释能力，仅少量站点出现 R^2 偏低甚至为负的情况，主要对应低客流、数据稀疏的站点，模型对这类站点的拟合效果受数据量限制有所下降。整体来看，模型在大部分站点的性能表现稳定，仅少数特殊站点存在性能短板，这一分布特征与地铁线网的客流特性高度契合，验证了模型在不同站点场景下的适用性与一致性。

综合上述多维度鲁棒性与稳定性验证结果，SeSTAR-Net 模型表现出优异的统计可靠性与场景适应性：Bootstrap 置信区间结果表明模型关键性能指标波动范围窄、分布集中，预测性能并非单次测试的偶然结果；MC-Dropout 不确定性估计显示模型对绝大多数样本的预测置信度较高，不确定性水平与客流场景难度匹配合理；输入噪声鲁棒性实验验证了模型对数据扰动的抗干扰能力，性能随噪声强度平滑衰减，未出现不可控的预测失效；逐日稳定性与站点级性能分布分析进一步表明，模型在时间与空间维度均表现出良好的一致性，仅少数特殊站点存在性能短板，整体符合地铁线网客流预测的实际特性。上述结果共同证明，SeSTAR-Net 模型具备在真实地铁运营场景中稳定部署与可靠应用的潜力。

第六章 结论与建议

6.1 主要结论

本研究以成都市地铁连续 31 天 AFC 刷卡数据为驱动，融合站点拓扑、7 维时间属性与包含 AQI 在内的 18 维外部环境数据，构建了 SeSTAR-Net 多分支残差混合预测模型，在 ARIMA、ConvLSTM、纯 GCN 和 ES-RNN 四种模型的全矩阵基准实验中完成了系统验证。综合第三章的数据处理流水线设计、第四章的时空特征分析、粒度效应检验、多模型对比与消融实验，形成以下五条结论。

第一，成都地铁客流兼具强周期规律与显著空间传导效应，为高精度预测提供了数据基础。热力图分析表明，客流日内分布呈现典型的双峰结构（小时波动系数 0.62），工作日与周末、节假日的形态差异清晰可辨。空间维度上，换乘站客流量约为普通站点的 2.5 至 4 倍，相邻站点进站量皮尔逊相关系数均值达 0.65（非相邻站点仅 0.20），上游站点客流变化在 15 至 30 分钟内可传导至下游。这些特征不仅解释了为何仅凭周期统计的 ARIMA 即可取得 R^2 约 0.86 的基线性能，也说明了引入图卷积空间编码器后性能大幅跃升的深层原因——空间传导信息是客流预测中除周期规律外最具信息量的独立信号源。

第二，SeSTAR-Net 通过“EMA 季节基线+残差学习+双流向分离编码+自注意力时序“的组合架构，在跨模型对比中全面领先。在 15 分钟粒度含外部特征配置下，SeSTAR-Net 取得 WMAPE=23.59%、R^2=0.9481 的全表最优成绩，WMAPE 较 ARIMA（33.25%）相对降低约 29%，较 ConvLSTM 最优配置（27.64%）降低 4.05 个百分点。四种模型的性能排序为 SeSTAR-Net> ConvLSTM>ARIMA > GCN，该排序在 5/10/15 分钟三种粒度及有/无外部特征共 6 组条件下保持高度稳健。值得注意的是，GCN 在所有配置下 WMAPE 均超过 65%、RMSE 为 SeSTAR-Net 的 3 至 4 倍——这一极端反差并非对图卷积的否定，而是反向证明了客流预测任务中时序建模与周期先验不可或缺：空间拓扑只在与其他信息源协同工作时才能释放其价值。

第三，残差学习范式的有效性得到了多角度验证。从训练曲线看，EMA 季节基线单独使用（消融变体−GCN/−Trans/−Sep）即可取得 WMAPE 27.3%，已优于 SARIMA。SeSTAR-Net 完整模型在此基础上仅需学习偏离基线的非线性残差，将 WMAPE 进一步压缩至 23.59%，且验证集损失在收敛后保持高度稳定（3 次独立运行标准差<0.2%）。基线对比图直观展示了这一机制：绿色季节基线已准确刻画了早晚高峰的位置和大致规模，橙色完整模型曲线在基线上叠加残差后，主要修正了峰值幅度偏差和时段特异性波动——残差编码器的工作量远小于从零预测的模型。这种先验加微调的策略兼具精度与稳健性优势：即使深度分支在个别异常时刻产生不合理输出，最终预测也被锚定在合理基线附近。

第四，预测粒度与外部数据分辨率之间的匹配关系决定了多源信息的实际价值。外部特征的贡献在三种粒度上呈现清晰的 U 型曲线：5 分钟粒度下加外部特征使 SeSTAR-Net 的 WMAPE 从 25.82%升至 27.29%（外部特征的高频前向填充噪声压倒了有效信号）；10 分钟粒度下两者趋近；15 分钟粒度下含外部特征的 WMAPE 从 24.28%降至 23.59%。这一规律的方法论含义是明确的——在难以获取分钟级高频环境数据的现实条件下，将预测粒度放宽至 15 分钟是充分发挥多源外部数据价值的工程最优选择。全矩阵对比表中 GCN 加外部特征后性能不升反降的现象也指向了同一结论：当模型本身缺乏基本的时序建模能力时，外部特征的附加信息无法被有效利用，反而成为额外噪声。

第五，十环节数据处理流水线为从原始 AFC 记录到模型可消费张量提供了完整的工程方案。本研究将整个数据链路分解为“多文件合并→累计差分→时间网格规整→外部循环编码→时间特征构造→站点筛选与图构建→分组标准化→长表转宽表→EMA 基线计算→滑动窗口切分”十个顺序环节，最终产出 5 路输入张量（进站流量、出站流量、时间特征、外部特征、季节基线）和 1 路标签。流水线的两个贯穿性设计原则是：所有操作严格按时间顺序执行（Scaler 仅在训练集拟合、EMA 仅用 t−1 天及以前信息、滑动窗口不打乱），以及在每个转换节点保留变量的物理含义（如风向和时间的正余弦循环编码、差分运算保留站点×日期分组结构）以支撑模型的可解释性。这套流水线不依赖于成都地铁数据的特有结构，对于其他城市的轨道交通 AFC 数据具有直接的可迁移性。

6.2 对策建议

基于上述结论，针对成都地铁运营管理提出四条具体建议。

第一，建立“预测—预警—响应”联动的动态运力调配机制。分时段误差分布图显示，模型在早晚高峰时段的预测精度足以支撑运力增量决策（峰值误差<10%），而平峰时段则可通过低客流预测降低发车频率以控制能耗。建议利用 SeSTAR-Net 模型在 15 分钟粒度下对各站点未来 1 至 3 小时客流的滚动预测，当预测客流超过站点设计承载能力的 80%时触发三级预警：黄色预警（80%–90%）启动站务备勤，橙色预警（90%–100%）执行区间加车或缩短行车间隔，红色预警（>100%）启动限流措施。换乘大站（天府广场、火车南站等）可根据预测的进站峰值时点，提前 15 分钟增配站务引导人员——15 分钟是本文验证的最优预测粒度，也与运营调度所需的前置时间匹配。

第二，制定多套差异化运行图以适应日期类型的结构性差异。逐日性能图和折线图分析一致表明，工作日双峰高耸（早晚高峰明显）、周末单峰平缓（客流集中在 11:00–17:00）、节假日前后的过渡日各有特殊形态。这三类日期之间不仅客流总量不同，时空分布模式也截然不同。建议制定三套基准运行图：工作

日执行“双峰强加密”，运力集中投放于 7:30–9:00 和 17:30–19:00；周末执行“全天均衡加密”，重点覆盖 11:00–17:00 休闲出行高峰；节假日重点布防节前一天下午（is_tomorrow_holiday 特征捕获的提前出行效应）、假期首日上午和返程日傍晚三个关键时点。当 AQI 预测达到中度污染（>150）且次日为周末时，可提前缩减非通勤时段运力——数据显示重度污染周末的进站量平均下降 12%。

第三，将客流空间传导规律纳入线网规划与换乘设计。消融实验表明，移除空间编码器是性能退化最严重的操作（WMAPE 升幅+4.39 个百分点），这从模型层面印证了线网拓扑对客流分布的强约束。具体而言，相邻站点间 0.65 的进站量相关系数意味着，当一个站点长期超载时，单纯加密该站点的发车频率效果有限——客流压力会沿轨道方向向上游和下游传导。在线网规划层面，对于长期超载的区段应优先考虑增设并行线路而非简单扩能；在换乘站设计层面，通道宽度和流线容量应基于上下游站点的预测客流进行容量核算，防止换乘节点成为系统性瓶颈。分站点性能图显示的精度梯度（换乘站 WMAPE 约 26.5%vs 普通站约 22.8%）也可用于指导站点周边的接驳设施密度分配——精度较低的换乘站周边应预留更多的弹性接驳空间。

第四，持续推进数据开放与模型工程化落地。训练曲线表明模型已在离线数据上实现稳定收敛，残差分布图显示预测误差接近正态且无系统性偏差，这为工程化部署提供了信心基础。建议分三步推进：短期内在运营控制中心部署离线版本，调度员根据日度更新预测调整次日运行图；中期对接实时 AFC 数据流和空气质量监测，实现 15 分钟滚动预测的在线推理；长期探索知识蒸馏或稀疏注意力等模型压缩方案，将推理延迟降至 5 分钟粒度实时预测的要求。在数据层面，建议开放更高频的外部环境数据（如分钟级 AQI 监测）和重大活动信息库——本文已证明外部数据的价值取决于其分辨率与预测粒度的匹配，高频数据有望打破当前 5 分钟粒度外部特征无效的瓶颈。

6.3 研究局限与未来展望

本研究在以下方面仍存在局限，也为后续工作指明了方向。

数据时间跨度有限，模型的季节泛化能力未经充分检验。本研究的 31 天数据虽然覆盖了工作日、周末和五一假期，但全部落在春夏之交（4–5 月），成都在此期间的客流模式受气候影响相对温和。寒暑假期间学生客流的大幅变化、春运期间的跨城客流冲击、夏季暴雨或冬季逆温导致的重度污染——这些场景在当前的训练和测试数据中均未出现。残差分布图中稍厚的尾部提示了部分意外时刻的存在，而这些时刻在更长时间跨度的数据中可能会以不同形式反复出现。未来应将数据扩至一年期以上，覆盖四季循环和各类特殊事件，并通过迁移学习或域自适应方法提升模型在不同季节和事件场景下的鲁棒性。

外部因素维度有限，黑天鹅事件的实时感知能力缺失。当前外部编码器仅接收天气、AQI 和日期标记三类静态或准静态变量。实时重大活动（演唱会、体育赛事）、线路临时故障、地面交通管制等突发事件对客流的冲击远大于 AQI 的慢性影响，但这些因素均未被纳入预测框架。现状下模型对此类事件的响应完全依赖于时序编码器从历史客流窗口中反向感知异常——这意味着预测只有在事件已开始影响客流后才可能做出调整。未来的改进方向是构建一个独立的事件信息编码通道，将重大活动日程、线路运营状态等动态信息以结构化的方式注入模型，使预测从被动反应转向主动预判。

模型尚未经历真实运营环境的在线检验。本研究属于事后评估性质，尽管在离线测试集上取得了 WMAPE=23.59%的成绩，但从实验台到控制室之间仍有一段落地的距离。在线部署面临的问题包括：实时 AFC 数据流的接入延迟、模型推理时间与 5 分钟更新频率的匹配、异常数据（如刷卡机临时故障导致的瞬时客流归零）的在线处理策略等。这些工程问题在离线环境中难以被充分暴露和验证。建议与成都地铁运营方协作，选定 3 至 5 个典型站点（覆盖换乘站、居住型和办公型各至少一个）开展为期 1 至 3 个月的在线试点，收集“预测→调度动作→实际客流→反馈修正”的完整闭环数据，在真实环境中迭代优化模型和调度策略。

模型结构存在继续优化的空间。当前的四分支架构虽然在精度上具有优势，但参数量较大——消融实验中移除任一分支均导致性能显著退化，说明各分支之间并非冗余关系。然而这并不意味着架构没有精简余地：时序 Transformer 的自注意力矩阵为 8×8，在 2 小时历史窗口下可能过度参数化；季节基线编码器的三全连接层也可通过结构搜索找到更紧凑的替代。未来可尝试的方向包括：用门控线性单元（GLU）或轻量级时序卷积替代 Transformer 以降低推理延迟，通过神经架构搜索（NAS）在精度与效率之间寻找帕累托最优配置，以及引入不确定性建模（如蒙特卡洛 Dropout 或深度集成）为每个预测输出附带的置信区间，使运营决策从点估计升级为风险量化。

通过上述数据、模型、工程三个维度的持续推进，有望构建一套从原始 AFC 数据自动流转至调度决策建议的端到端智慧客流管理闭环，真正实现本研究的初衷——将深度学习客流预测从学术实验推向生产级应用，为城市轨道交通的安全、绿色与智能化运营提供经得起实践检验的技术支撑。

参考文献

[1] Zhu K, Xun P, Li W, et al. Prediction of passenger flow in urban rail transit based on big data analysis and deep learning [J]. IEEE Access, 2019, 7: 142272-142279.

[2] 强添纲, 刘涛, 裴玉龙. 地铁进站客流量 SARIMA 与 GA-BP 神经网络组合预测模型[J]. 铁道运输与经济, 2021, 43(12): 134-142.

[3] Liu J, Jiang R, Zhu D, et al. Short-term subway inbound passenger flow prediction based on AFC Data and PSO-LSTM optimized model [J]. Urban Rail Transit, 2022, 8(1): 56-66.

[4] Wu J, He D, Li X, et al. A time series decomposition and reinforcement learning ensemble method for short-term passenger flow prediction in urban rail transit [J]. Urban Rail Transit, 2023, 9(4): 323-351.

[5] Katambire V N, Musabe R, Uwitonze A, et al. Forecasting the traffic flow by using ARIMA and LSTM models: case of Muhima junction [J]. Forecasting, 2023, 5(4): 616-628.

[6] Luo X, Li D, Yang Y, et al. Spatiotemporal traffic flow prediction with KNN and LSTM [J]. Journal of Advanced Transportation, 2019, 2019(1): 4145353-4145363.

[7] Park Y, Choi Y, Kim K, et al. Machine learning approach for study on subway passenger flow [J]. Scientific Reports, 2022, 12(1): 2754-2774.

[8] Han Y, Wang S, Ren Y, et al. Predicting station-level short-term passenger flow in a citywide metro network using spatiotemporal graph convolutional neural networks [J]. ISPRS International Journal of Geo-Information, 2019, 8: 243.

[9] Zheng H, Lin F, Feng X, et al. A hybrid deep learning model with attention-based conv-LSTM networks for short-term traffic flow prediction [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(11): 6910-6920.

[10] Zhao C, Li X, Shao Z, et al. Multi-featured spatial-temporal and dynamic multi-graph convolutional network for metro passenger flow prediction [J]. Connection Science, 2022, 34(1): 1252-1272.

[11] Hou Z, Du Z, Yang G, et al. Short-term passenger flow prediction of urban rail transit based on a combined deep learning model [J]. Applied Sciences, 2022, 12(15): 7597-7615.

[12] Zhang J, Chen F, Cui Z, et al. Deep learning architecture for short-term passenger flow forecasting in urban rail transit [J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 22(11): 7004-7014.

[13] Zeng J, Tang J. Combining knowledge graph into metro passenger flow prediction: A split-attention relational graph convolutional network [J]. Expert Systems with Applications, 2023, 213: 118790-118823.

[14] 张阳, 陈燕玲. 多头图注意机制的深度学习地铁客流预测方法[J]. 铁道运输与经济, 2024, 46(02): 167-175.

[15] Tang J, Zhu R, Wu F, et al. Deep spatio-temporal dependent convolutional LSTM network for traffic flow prediction [J]. Scientific Reports, 2025, 15(1): 11743-11758.